

Αριστοτέλειο Πανεπιστήμιο Θεσσαλονίκης
Τμήμα Ηλεκτρολόγων Μηχανικών και Μηχανικών Υπολογιστών
Τομέας Τηλεπικοινωνιών



Μπουκουτσού Μαρία , ΑΕΜ: 9452

ΔΙΠΛΩΜΑΤΙΚΗ ΕΡΓΑΣΙΑ

Εκτίμηση κινητικής κατάστασης ατόμων με χρήση Αποσύνθεσης Σμήνους και
Βαθιάς Μηχανικής Μάθησης σε δεδομένα ear-EEG 14 καναλιών
Human motion estimation using swarm decomposition and deep learning on
14 ear-EEG channel data

Επιβλέπων Καθηγητής: Λεόντιος Χατζηλεοντιάδης

Θεσσαλονίκη, Ιούνιος 2023

© Μπουκουτσού Μαρία

© Α.Π.Θ.

Εκτίμηση κινητικής κατάστασης ατόμων με χρήση Αποσύνθεσης Σμήνους και Βαθιάς Μηχανικής Μάθησης σε δεδομένα ear-EEG 14 καναλιών

«Η έγκριση της παρούσης Διδακτορικής Διατριβής από το Τμήμα Ηλεκτρολόγων Μηχανικών και Μηχανικών Υπολογιστών του Αριστοτελείου Πανεπιστημίου Θεσσαλονίκης δεν υποδηλώνει αποδοχή των γνώμων του συγγραφέως»

(Ν. 5343/1932, άρθρο 202, παρ. 2)

Στην οικογένειά μου

Περίληψη

Το ηλεκτροεγκεφαλογράφημα από την περιοχή του αυτιού (**ear-EEG**) αποτελεί μια τεχνική καταγραφής της ηλεκτρικής δραστηριότητας του εγκεφάλου με χρήση ηλεκτροδίων που, όπως φανερώνει και το όνομά του, τοποθετούνται πάνω ή μέσα στο αυτί. Η τεχνική αυτή έχει πολλά πιθανά πλεονεκτήματα συγκριτικά με το παραδοσιακό ηλεκτροεγκεφαλογράφημα του τριχωτού της κεφαλής (EEG) αφού προσφέρει μια πιο φορητή και άνετη λύση, μιας και τα ηλεκτρόδια μπορούν να ενσωματωθούν σε φορητές συσκευές, όπως ακουστικά ή βοηθήματα ακοής. Σημειώνεται πως η νέα τεχνολογία ear-EEG είναι πολλά υποσχόμενη, αλλά δεν είναι ακόμη ευρέως διαδεδομένη λόγω της ανάγκης διεξαγωγής περαιτέρω έρευνας σχετικά με τις δυνατότητες που μπορεί να προσφέρει αλλά και τους περιορισμούς που επιδέχεται.

Στην παρούσα διπλωματική εργασία μελετάται το σήμα ear-EEG υγιών ατόμων όταν παρουσιάζονται οπτικά ερεθίσματα κατά τη διάρκεια μιας διαδικασίας διάκρισης στόχου με παράλληλη βάδιση σε διαφορετικές ταχύτητες, με σκοπό την εκτίμηση της κινητικής κατάστασης των ατόμων κατά την υλοποίηση του πειράματος. Στην βιβλιογραφία, η ανάλυση σημάτων εγκεφαλικής δραστηριότητας για προβλήματα ταξινόμησης, συνήθως, υλοποιείται με εξαγωγή χαρακτηριστικών από τη μορφή των σημάτων στα πεδία του χρόνου και της συχνότητας, τα οποία στη συνέχεια εισάχονται σε αλγόριθμους μηχανικής μάθησης. Εντούτοις, εδώ προτείνεται η χρήση δικτύου βαθιάς μηχανικής μάθησης (**Deep Learning**), και συγκεκριμένα η χρήση συνελικτικού νευρωνικού δικτύου, με στόχο την αναγνώριση προτύπων στις κυματομορφές των σημάτων ηλεκτροεγκεφαλογραφήματος. Μια ακόμη ενέργεια που διαφοροποιεί την παρούσα ερευνητική προσπάθεια, είναι ότι ενώ κατά κύριο λόγο, επιδιώκεται αφαίρεση οποιασδήποτε μορφής artifacts από τα σήματα κατά τη διαδικασία προεπεξεργασίας, στην δεδομένη περίπτωση επιδιώχθηκε να παραμείνουν τα artifacts που προκαλούνται λόγω της κίνησης των ατόμων (moving artifacts), ώστε να γίνει κατανοητό αν η παρουσία τους συμβάλλει στην ευκολότερη εκτίμηση της κινητικής κατάστασής τους.

Τα συνελικτικά δίκτυα είναι γνωστό πως δέχονται ως είσοδο δεδομένα σε μορφή εικόνας. Για το λόγο αυτό, τα δεδομένα ηλεκτροεγκεφαλογραφήματος από την περιοχή του αυτιού μετασχηματίζονται σε μορφή εικόνας με χρήση της τεχνικής αποσύνθεσης σμήνους (**Swarm Decomposition**), με την οποία κάθε σήμα κάθε ηλεκτροδίου αποσυντίθεται, αναλύεται δηλαδή, σε απλούστερες συχνοτικά συνιστώσες. Τελικά, τα δεδομένα που εισάγονται στο συνελικτικό δίκτυο έχουν τη μορφή: $S \times C \times OC$, όπου S (samples) είναι τα δείγματα στο πεδίο της συχνότητας, C (Channels) τα κανάλια και OC (Oscillatory Modes) οι συχνοτικές συνιστώσες που προκύπτουν μετά την αποσύνθεση σμήνους. Σημειώνεται πως γίνεται χρήση συνελικτικών δικτύων με σχετικά μικρό βάθος (σχετικά μικρός αριθμός επιμέρους επιπέδων) καθώς επιδιώκεται η διατήρηση μικρού χρόνου εκπαίδευσης και πολυπλοκότητας του δικτύου, αλλά και επιβεβαίωση πως η χρήση αποσύνθεσης σμήνους συνδράμει ώστε να είναι ευκολότερη η δυνατότητα αναγνώρισης προτύπων για τα σήματα που προέκυψαν όταν τα άτομα βρίσκονταν σε διαφορετική κινητική κατάσταση.

Abstract

The electroencephalogram from the area of the ear (**ear-EEG**) is a technique that involves recording the electrical activity of the brain using electrodes that are placed on or inside the ear. This technique has many potential advantages over traditional scalp EEG, since it offers a more portable and comfortable solution, as the electrodes can be integrated into portable devices such as headphones or hearing aids. It is mentioned that the new ear-EEG technology is really promising, but it is not yet widespread due to the need to conduct further research on its possibilities and its limitations.

In this thesis, ear-EEG signals of healthy subjects are studied when visual stimuli are presented during a target discrimination process while walking at different speeds, with the aim of assessing the subjects' kinetic state during the implementation of the experiment. In relevant literature, the analysis of brain activity signals for classification problems is usually implemented by extracting features from time and frequency domains, which are then utilized in machine learning algorithms. However, the use of a **deep learning** network is proposed in this thesis, and more specifically, the use of a convolutional neural network, in order to recognize patterns in the waveforms of EEG signals. Another action that differentiates the present research effort, is that while most of the times, it is sought to remove all form of artifacts from the signals during the preprocessing, in our case it was sought to retain the artifacts caused due to the movement of individuals (moving artifacts), in order to realize whether their presence contributes to an easier assessment of their kinetic state.

It is known that convolutional neural networks (CNN) receive, mostly, image formats data as inputs. For this reason, the ear-EEG signals are transformed in an image like format using the technique of **swarm decomposition**. By using this technique, every signal of every electrode is decomposed into simpler oscillatory components. Finally, the CNN input data have the following structure: $S \times C \times OC$, where S are the Samples in the frequency domain, C are the ear-EEG Channels and OC are the Oscillatory Modes occuring after the swarm decomposition. The convolutional neural networks that are used have a relatively small depth (not that many layers) in order to maintain a short training time and small complexity, as it is wanted to confirm that the use of swarm decomposition aids to facilitate the recognition of different patterns in signals occuring when subjects were in a different motion state.

Ευχαριστίες

Με την εκπόνηση της παρούσας διπλωματικής εργασίας ολοκληρώνεται η φοίτησή μου ως προπτυχιακή φοιτήτρια στο τμήμα Ηλεκτρολόγων Μηχανικών και Μηχανικών Υπολογιστών του Αριστοτελείου Πανεπιστημίου Θεσσαλονίκης. Θα ήθελα να ευχαριστήσω τον επιβλέποντα καθηγητή μου Λεόντιο Χατζηλεοντιάδη για την εμπιστοσύνη που μου έδειξε με την ανάθεση του εν λόγω θέματος διπλωματικής εργασίας. Ακόμη, θα επιθυμούσα να κάνω μια ιδιαίτερη αναφορά στο Εργαστήριο Επεξεργασίας Σήματος και Βιοϊατρικής Τεχνολογίας, και συγκεκριμένα στην Ιωάννα Αβραμίδου και στον Γιώργο Αποστολίδη, και να τους ευχαριστήσω για την καθοδήγηση και τις συμβουλές τους. Επίσης, θα ήθελα να ευχαριστήσω τους γονείς μου, Αναστασία και Κωνσταντίνο, τα αδέρφια μου, Φωτεινή και Κλεάνθη, και τους δικούς μου ανθρώπους για την αγάπη και την στήριξη που μου δείχνουν σε κάθε βήμα της ζωής μου.

Περιεχόμενα

Περίληψη	i
Abstract	ii
Ευχαριστίες	iii
1 Εισαγωγή	1
1.1 Σκοπός της διπλωματικής εργασίας	1
1.2 Δομή της διπλωματικής εργασίας	2
2 Μελέτη Εγκεφαλικής Δραστηριότητας	3
2.1 Ο ανθρώπινος εγκέφαλος	3
2.2 Δομή και Λειτουργία Νευρώνα	4
2.3 Το Ηλεκτροεγκεφαλογράφημα	5
2.3.1 Εγκεφαλικοί Ρυθμοί	8
2.3.2 Σήματα Μη Εγκεφαλικής Προέλευσης - Artifacts	10
2.3.3 Προκλητά δυναμικά - Event Related Potentials (ERPs)	10
2.4 Το Ηλεκτροεγκεφαλογράφημα από την περιοχή του αυτιού (ear-EEG)	12
2.5 Κίνηση και Ηλεκτροεγκεφαλογράφημα	14
2.5.1 Moving artifacts στο EEG	15
3 Θεωρητικό Υπόβαθρο	17
3.1 Αποσύνθεση Σμήνους - (Swarm Decomposition - SWD)	17
3.2 Μηχανική Μάθηση	20
3.3 Βασικές Κατηγορίες αλγορίθμων μηχανικής μάθησης	22
3.3.1 Ταξινόμηση	22
3.3.2 Ομαδοποίηση	25
3.4 Βαθιά Μηχανική Μάθηση	27
3.4.1 Νευρωνικά δίκτυα	27
3.4.2 Συνελικτικά Νευρωνικά Δίκτυα	29
4 Πειραματική Διαδικασία	37
4.1 Δεδομένα	38
4.2 Συμμετέχοντες και ERP tasks	38
4.3 Ear-EEG Σήματα	39
5 Παρουσίαση της μεθόδου	45

5.1	Προεπεξεργασία σημάτων (Preprocessing)	45
5.1.1	Αρχικός Αριθμός Σημάτων ear-EEG	45
5.2	Εφαρμογή αποσύνθεσης Σμήνους	48
6	Δημιουργία Συνελικτικού Μοντέλου	55
6.1	Δημιουργία των συνόλων εκπαίδευσης, επικύρωσης και δοκιμής	55
6.2	Δομή του Συνελικτικού Δικτύου	56
6.3	Αξιολόγηση του Συνελικτικού Δικτύου	59
6.4	Διαστήματα Εμπιστοσύνης για τις μετρικές του μοντέλου	60
6.4.1	Μέθοδος κανονικής προσέγγισης διαστημάτων	61
6.4.2	Μέθοδος bootstrapping του συνόλου δοκιμής	62
6.4.3	Τελικά Διαστήματα Εμπιστοσύνης	62
6.5	Αξιολόγηση της πληροφορίας που οδηγεί το Συνελικτικό Δίκτυο στην Απόφαση . .	63
6.5.1	Εντοπισμός της συχνοτικής περιοχής των Oscillatory Modes που προσφέρει την πιο χρήσιμη πληροφορία	64
6.5.2	Εντοπισμός των καναλιών που προσφέρουν την πιο χρήσιμη πληροφορία . .	65
7	Ανακεφαλαίωση και Μελλοντικές Προεκτάσεις	67
	Α΄ Εργαλεία	69
	Βιβλιογραφία	71

Κατάλογος Σχημάτων

2.1	Αριστερό εγκεφαλικό ημισφαίριο	4
2.2	Βασική δομή νευρικού κυττάρου	4
2.3	Διέγερση νευρικού κυττάρου	6
2.4	International system 10-20	7
2.5	Καταγραφή ΗΕΓ μέσω ηλεκτροδίων τοποθετημένων στο κρανίο του ατόμου	8
2.6	Εγκεφαλικοί ρυθμοί	9
2.7	Μορφή διάφορων Artifacts	11
2.8	average ERP ενός ατόμου για το ηλεκτρόδιο O1 (Ινιακός Λοβός)	12
2.9	Καταγραφή ear-EEG	13
3.1	Φιλτράρισμα Σμήνους	19
3.2	Αποσύνθεση Σμήνους	19
3.3	Χωρισμός των δεδομένων σε τρία υποσύνολα (sets)	22
3.4	Πίνακας Σύγχυσης	23
3.5	ROC καμπύλη	24
3.6	k-means Clustering	26
3.7	DBSCAN	27
3.8	Σύγκριση των αλγορίθμων k-means και DBSCAN	27
3.9	Απεικόνιση τεχνητού νευρώνα	28
3.10	Δομή Νευρωνικού Δικτύου	29
3.11	Συνελικτικό Νευρωνικό Δίκτυο	30
3.12	Συναρτήσεις Ενεργοποίησης	32
3.13	Παράδειγμα Max και Average Pooling	33
3.14	Παράδειγμα Fully connected layer που υλοποιεί ταξινόμηση σε 5 κλάσεις	34
3.15	Επίπεδο Αποκοπής Νευρώνων	35
4.1	Experimental design	37
4.2	Θέσεις ηλεκτροδίων ear-EEG	38
4.3	ERP tasks	39
4.4	ear-EEG signal για κάθε session κίνησης	40
4.5	Average Target and non-Target signals for the 4 different speeds: 0 m/s, 0.8 m/s, 1.6 m/s and 2 m/s	41
4.6	Average Target and non-Target signals for the speeds: 0 m/s and 2 m/s	42
4.7	Power Spectral Densities of average Target and Non-Target signals for speeds: 0 m/s and 2 m/s	43

5.1	Διάγραμμα Ροής	45
5.2	Problematic recordings	46
5.3	Ποσοστό trials με προβληματικά σήματα	48
5.4	Ποσοστό προβληματικών trials	48
5.5	Initial Signals in time and frequency domain	49
5.6	SWD Parameters	50
5.7	Oscillatory Modes after Swarm Decomposition	51
5.8	Oscillatory Modes after Swarm Decomposition	53
6.1	Balance of the training set	56
6.2	Balance of the validation set	57
6.3	Balance of the test set	57
6.4	Μέγεθος των συνόλων	58
6.5	Παράμετροι που προέκυψαν μετά την εφαρμογή του hyper parameter tuning	58
6.6	Ακρίβεια και απώλεια για το σύνολο δοκιμής	59
6.7	Πίνακας σύγχυσης	60
6.8	Classification Report	60
6.9	ROC καμπύλη	61
6.10	Διαστήματα Εμπιστοσύνης για την Ακρίβεια του μοντέλου	62
6.11	Διαστήματα Εμπιστοσύνης για την Αξιοπιστία του μοντέλου	63
6.12	Διαστήματα Εμπιστοσύνης για την Ανάκληση του μοντέλου	63
6.13	Διαστήματα Εμπιστοσύνης για τον Παράγοντα F1 του μοντέλου	63
6.14	Accuracy Score	64
6.15	Accuracy Score	65
6.16	Accuracy Score	66
6.17	Accuracy Score	66

Κεφάλαιο 1

Εισαγωγή

Η ανάπτυξη της τεχνολογίας έχει οδηγήσει στη γέννηση ενός νέου κλάδου που ονομάζεται βιοϊατρική μηχανική (biomedical engineering) και συνδυάζει αρχές της μηχανικής και της βιολογίας για την αντιμετώπιση των προκλήσεων στην υγειονομική περίθαλψη και την ιατρική. Ένα από τα πεδία έρευνας που συγκεντρώνει τεράστιο ενδιαφέρον είναι η μελέτη του ανθρώπινου εγκεφάλου, μιας και η κατανόηση της λειτουργίας του είναι πολύπλοκη και τα ερωτήματα σχετικά με αυτή παραμένουν αναρίθμητα.

Η ανάγκη καταγραφής και μέτρησης της εγκεφαλικής δραστηριότητας οδήγησε στην γέννηση της τεχνικής του ηλεκτροεγκεφαλογραφήματος (EEG) και μεταγενέστερα του ηλεκτροεγκεφαλογραφήματος από την περιοχή του αυτιού (ear-EEG). Το ear-EEG αποτελεί μια πιο φορητή και άνετη λύση και επιτρέπει την καταγραφή της εγκεφαλικής δραστηριότητας κατά την καθημερινή ζωή των ατόμων σε πραγματικά περιβάλλοντα, δηλαδή εκτός περιβαλλόντων εργαστηρίου. Η νέα αυτή τεχνική είναι πολλά υποσχόμενη αλλά περαιτέρω έρευνα είναι απαραίτητη ώστε να κατανοηθούν καλύτερα οι δυνατότητες που μπορεί να προσφέρει.

Στην παρούσα εργασία γίνεται μια προσπάθεια αναγνώρισης της κινητικής κατάστασης (ακινήσια ή κίνηση) των ατόμων όταν εμφανίζονται οπτικά ερεθίσματα κατά τη διάρκεια μιας διαδικασίας διάκρισης στόχου με παράλληλη βάδιση σε διάφορες ταχύτητες μετά από επεξεργασία των σημάτων ηλεκτροεγκεφαλογραφήματος από την περιοχή του αυτιού.

1.1 Σκοπός της διπλωματικής εργασίας

Σκοπός της παρούσας διπλωματικής εργασίας είναι η χρήση καινοτόμου συνδυασμού μεθόδων για την ανάλυση σημάτων ηλεκτροεγκεφαλογραφήματος από την περιοχή του αυτιού με στόχο την εκτίμηση της κινητικής κατάστασης των ατόμων κατά την διέγερση του εγκεφάλου. Ο εγκέφαλος διεγείρεται με οπτικά ερεθίσματα (εικόνες στόχου/ μη-στόχου) κατά τη διάρκεια μιας διαδικασίας διάκρισης στόχου με παράλληλη βάδιση σε διαφορετικές ταχύτητες. Αρχικά, εφαρμόστηκε επεξεργασία των δεδομένων και αφαιρέθηκαν τα προβληματικά σήματα ορισμένων καναλιών. Όσον αφορά την υπολογιστική πλευρά της εργασίας, διερευνήθηκε η δυνατότητα χρήσης βαθιάς μηχανικής μάθησης, και συγκεκριμένα συνελικτικών νευρωνικών δικτύων, αντί των συνηθισμένων αλγορίθμων μηχανικής μάθησης για το πρόβλημα της ταξινόμησης. Χρησιμοποιήθηκε η τεχνική Αποσύνθεσης Σμήνους ώστε τα δεδομένα να μετασχηματιστούν σε μορφή εικόνας, μορφή που δέχονται ως είσοδο τα συνελικτικά δίκτυα, ενώ παράλληλα με τη χρήση της τεχνικής, κάθε σήμα κάθε καναλιού

αναλύθηκε σε απλούστερες συχνοτικά συνιστώσες. Αναφέρεται πως για το συγκεκριμένο είδος δεδομένων (σήματα ηλεκτροεγκεφαλογράφηματος από την περιοχή του αυτιού) πραγματοποιείται ένας συνδυασμός μεθόδων που δεν έχει εφαρμοστεί ξανά στη σχετική βιβλιογραφία.

1.2 Δομή της διπλωματικής εργασίας

Η παρούσα διπλωματική εργασία αποτελείται από 7 Κεφάλαια και η δομή της είναι η ακόλουθη:

- Στο Κεφάλαιο 1 περιγράφεται συνοπτικά το θέμα με το οποίο ασχολείται η διπλωματική εργασία και παρουσιάζεται η δομή της.
- Στο Κεφάλαιο 2 γίνεται ανάλυση των βασικών εννοιών που αφορούν τη λειτουργία του εγκεφάλου και το ηλεκτροεγκεφαλογράφημα, ώστε ο αναγνώστης να αποκτήσει κάποιες βασικές γνώσεις για τα πεδία αυτά.
- Στο Κεφάλαιο 3 παρουσιάζεται το θεωρητικό υπόβαθρο που απαιτείται για την κατανόηση της παρούσας διπλωματικής εργασίας. Πιο συγκεκριμένα, γίνεται ανάλυση της διαδικασίας Αποσύνθεσης Σιγμάτων, της Μηχανικής Μάθησης και της Βαθιάς Μηχανικής Μάθησης.
- Στο Κεφάλαιο 4 περιγράφεται η πειραματική διαδικασία.
- Στο Κεφάλαιο 5 παρουσιάζεται ενδελεχώς η μέθοδος που χρησιμοποιήθηκε.
- Στο Κεφάλαιο 6 αναλύεται η διαδικασία δημιουργίας του συνελκτικού μοντέλου και γίνεται αξιολόγησή του.
- Στο Κεφάλαιο 7 ανακεφαλαιώνονται τα τελικά συμπεράσματα, ενώ παράλληλα παρουσιάζονται κατευθύνσεις για περαιτέρω μελλοντική έρευνα.

Κεφάλαιο 2

Μελέτη Εγκεφαλικής Δραστηριότητας

2.1 Ο ανθρώπινος εγκέφαλος

Το νευρικό σύστημα του ανθρώπου διαχωρίζεται στο Περιφερικό Νευρικό Σύστημα(ΠΝΣ) και Κεντρικό Νευρικό Σύστημα (ΚΝΣ). Το ΚΝΣ αποτελείται από τον εγκέφαλο και το νωτιαίο μυελό. Ο εγκέφαλος είναι το όργανο που ελέγχει όλες τις λειτουργίες του ανθρώπινου σώματος, όπως οι αισθήσεις, η αντίληψη, ο έλεγχος και ο συντονισμός των μυικών κινήσεων, αλλά και ανώτερες πνευματικές λειτουργίες. Η κύρια λειτουργική μονάδα του ανθρώπινου εγκεφάλου είναι το νευρικό κύτταρο (ή νευρώνας). Πιο συγκεκριμένα, στην περιοχή του εγκεφάλου εντοπίζονται πάνω από 100 δισεκατομμύρια νευρώνες, οι οποίοι είναι σχεδιασμένοι ώστε να δέχονται, να επεξεργάζονται και να μεταβιβάζουν ερεθίσματα.

Ο εγκέφαλος βρίσκεται μέσα στο κρανίο, καλύπτεται από τρεις προστατευτικές μεμβράνες, που ονομάζονται μήνιγγες, και περιβάλλεται από το εγκεφαλονωτιαίο υγρό. Επιπλέον, χωρίζεται ανατομικά σε τρεις περιοχές, τα εγκεφαλικά ημισφαίρια, το στέλεχος και την παρεγκεφαλίδα.

Τα εγκεφαλικά ημισφαίρια, το δεξί και το αριστερό, χωρίζονται μεταξύ τους από την επιμήκη σχισμή. Δεν έχουν συμμετρική λειτουργία, αλλά το καθένα είναι υπεύθυνο για διαφορετικές δεξιότητες και αντιληπτικές ικανότητες. Πιο συγκεκριμένα, το δεξί ημισφαίριο ελέγχει λειτουργίες όπως η χωρική αντίληψη, η επικοινωνία και η κατανόηση συναισθημάτων, ενώ το αριστερό λειτουργίες όπως η αντίληψη, η ομιλία, η γραφή. Ωστόσο, στην περίπτωση κάποιας βλάβης στο ένα ημισφαίριο, το άλλο μπορεί να αναπληρώσει ως ένα βαθμό τις λειτουργίες του. Το δεξί ημισφαίριο δέχεται τα ερεθίσματα από το αριστερό τμήμα του σώματος και ελέγχει τις κινήσεις αυτού, ενώ το αντίστροφο ισχύει για το αριστερό. Κάθε ημισφαίριο χωρίζεται σε τέσσερις λοβούς (Σχήμα 2.1 [1]) που είναι οι ακόλουθοι:

- ο μετωπιαίος λοβός (frontal lobe)
- ο βρεγματικός λοβός (parietal lobe)
- ο ινιακός λοβός (occipital lobe)
- ο κροταφικός λοβός (temporal lobe)

Οι λοβοί δεν λειτουργούν σαν ανεξάρτητες μονάδες, αλλά υπάρχει αλληλεπίδραση μεταξύ όχι μόνο αυτών που ανήκουν στο ίδιο ημισφαίριο, αλλά και αυτών που ανήκουν σε διαφορετικά.




Σχήμα 2.1: Αριστερό εγκεφαλικό ημισφαίριο

Το εγκεφαλικό στέλεχος δομικά αποτελεί συνέχεια του νωτιαίου μυελού, βρίσκεται κάτω από τα εγκεφαλικά ημισφαίρια και χωρίζεται σε τρία τμήματα, τον μεσεγκέφαλο, τη γέφυρα και τον προμήχη μυελό. Ρυθμίζει πολλές ζωτικές λειτουργίες του σώματος, όπως τη συχνότητα του παλμού της καρδιάς, την πίεση του αίματος και τον ρυθμό της αναπνοής. Όλα τα ερεθίσματα που μεταδίδονται από τον εγκέφαλο στο σώμα και αντίστροφα, διέρχονται από το στέλεχος.

Τέλος, η παρεγκεφαλίδα, η οποία βρίσκεται στο πίσω μέρος του εγκεφάλου, συμμετέχει κυρίως στη ρύθμιση της θέσης και της ισορροπίας, αλλά και στον έλεγχο της κεφαλής και των οφθαλμών. Στο Σχήμα 2.1 φαίνεται και η παρεγκεφαλίδα στο κάτω μέρος του εγκεφαλικού ημισφαιρίου.

2.2 Δομή και Λειτουργία Νευρώνων

Τα νευρικά κύτταρα (ή νευρώνες) αποτελούν τα κύρια δομικά και λειτουργικά μέρη του εγκεφάλου και αποτελούνται από τρία βασικά μέρη: το κυτταρικό σώμα (cell body), τους δενδρίτες (dendrites) και τον άξονα (axon). Η μορφή ενός νευρώνα απεικονίζεται στο Σχήμα 2.2 [2].



Σχήμα 2.2: Βασική δομή νευρικού κυττάρου

1. Στο κυτταρικό σώμα εντοπίζεται ο πυρήνας, ο οποίος περιέχει το γενετικό υλικό και ελέγχει τις δραστηριότητες του κυττάρου.

2. Οι δονδρίτες αποτελούν νευρικές απολήξεις που εξέρχονται από το κυτταρικό σώμα και διακλαδίζονται δημιουργώντας μια μορφή δένδρου (από όπου πήραν και το όνομά τους). Είναι υπεύθυνοι για την λήψη των ερεθισμάτων και τη μεταφορά τους στο κυτταρικό σώμα.
3. Ο άξονας είναι υπεύθυνος για τη διάδοση των ερεθισμάτων σε άλλους νευρώνες που δημιουργούνται στη συμβολή του άξονα με το σώμα. Αποτελούν, λοιπόν, κατά μία έννοια την έξοδο του κυττάρου.

Οι νευρώνες είναι διεγέρσιμα κύτταρα, πράγμα που σημαίνει πως αντιδρούν και παράγουν ηλεκτρισμό [3]. Στην κατάσταση ηρεμίας, τα διεγέρσιμα κύτταρα έχουν ένα διαμεμβρανικό δυναμικό, το λεγόμενο δυναμικό ηρεμίας. Ουσιαστικά, στην κατάσταση ηρεμίας το εσωτερικό του κυττάρου βρίσκεται σε δυναμικό περίπου ίσο με -70 mV σε σχέση με το εξωτερικό μέρος του, γεγονός που προκαλείται λόγω των διαφορετικών συγκεντρώσεων ιόντων στα διαλύματα εκατέρωθεν της κυτταρικής μεμβράνης του κυττάρου.


Όταν το κύτταρο διεγερθεί κατάλληλα αλλάζει η διαμεμβρανική διαφορά δυναμικού εκατέρωθεν της μεμβράνης και λαμβάνει την τιμή $+40 \text{ mV}$. Το δυναμικό αυτό στο οποίο βρίσκεται το κύτταρο μετά την διέγερσή του καλείται ενεργό δυναμικό (ή δυναμικό ενέργειας). Αυτή η κατάσταση αναφέρεται ως δίπολο [4]. Στη συνέχεια, το κύτταρο επανέρχεται και πάλι στην κατάσταση ηρεμίας, όπως είναι φανερό στο Σχήμα 2.3 [5]. Πιο αναλυτικά, κατά τη διέγερση του κυττάρου, αρχικά το δυναμικό της μεμβράνης αυξάνεται και συγκλίνει προς την μέγιστη τιμή των $+40 \text{ mV}$ (διαδικασία εκπόλωσης). Στη συνέχεια, έρχεται η φάση της επαναπόλωσης, κατά την οποία το κύτταρο τείνει να φτάσει σε κατάσταση ηρεμίας. Ωστόσο, πριν φτάσει μόνιμα στην κατάσταση ηρεμίας, την ξεπερνά για ένα μικρό χρονικό διάστημα, κατά το οποίο το δυναμικό της μεμβράνης του κυττάρου καταλήγει να είναι πιο αρνητικό από το δυναμικό ηρεμίας (υπερπόλωση).

Η επικοινωνία μεταξύ δύο νευρικών κυττάρων γίνεται μέσω των συνάψεων. Η μεταβίβαση της μεταβολής δυναμικού κατά μήκος του νευρικού κυττάρου, ονομάζεται νευρική ώση και αποτελεί το μηχανισμό με τον οποίο το μήνυμα που ευαισθητοποιεί το νευρώνα μεταβιβάζεται σε άλλα κύτταρα.

2.3 Το Ηλεκτροεγκεφαλογράφημα

Η πρώτη παρουσίαση ευρημάτων σχετικά με τα ηλεκτρικά φαινόμενα εγκεφαλικών ημισφαιρίων πραγματοποιήθηκε το 1875 από τον Βρετανό γιατρό Richard Caton, ο οποίος μελέτησε εγκεφάλους κουνελιών και πιθήκων. Η συμβολή του για την ανακάλυψη της ηλεκτρικής φύσης του εγκεφάλου ήταν καθοριστική και έθεσε τις βάσεις, έτσι ώστε το 1924 ο Γερμανός ψυχίατρος Hans Berger να κάνει την πρώτη καταγραφή ΗΕΓ κατά τη διάρκεια μιας νευροχειρουργικής επέμβασης σε ένα 17χρονο αγόρι, που έγινε από τον νευροχειρουργό Nikolai Guleke [6]. Η ανακάλυψη του ηλεκτροεγκεφαλογραφήματος αποτέλεσε μια ιστορική ανακάλυψη και αποτέλεσε ένα αδιαμφισβήτητο χρήσιμο νευρολογικό και ψυχιατρικό διαγνωστικό εργαλείο, ειδικά για μια εποχή που μέθοδοι εξέτασης όπως η ακτινογραφία και η μαγνητική τομογραφία δεν είχαν ακόμη ανακαλυφθεί.

Το ηλεκτροεγκεφαλογράφημα (ΗΕΓ) ουσιαστικά αποτελεί μια ευρέως χρησιμοποιούμενη μη επεμβατική μέθοδο για την παρακολούθηση της δραστηριότητας του εγκεφάλου. Βασίζεται στην τοποθέτηση αγωγικών ηλεκτροδίων στο τριχωτό της κεφαλής που μετρούν τα ηλεκτρικά δυναμικά (διαφορά δυναμικού) που προκύπτουν έξω από το κεφάλι και οφείλονται στη νευρωνική δράση μέσα




Σχήμα 2.3: Διέγερση νευρικού κυττάρου

στον εγκέφαλο, δηλαδή στην διέγερση των νευρικών κυττάρων του εγκεφάλου. Τα ηλεκτρόδια αυτά συνδέονται είτε κατευθείαν στο κρανίο του ατόμου του οποίου η εγκεφαλική δραστηριότητα επιθυμείται να καταγραφεί, είτε πάνω σε έναν ελαστικό καπέλο (electrode cap) που τοποθετείται στη συνέχεια στο κρανίο (non invasive EEG). Προκειμένου να βελτιωθεί η επαφή με το κρανίο, πολλές φορές εφαρμόζεται και κάποιο αγώγιμο τζελ στα ηλεκτρόδια.

Στο σημείο αυτό, κρίνεται απαραίτητο να τονιστεί ότι το δίπολο ενός μεμονωμένου νευρώνα είναι πολύ μικρό για να μετρηθεί από ηλεκτρόδιο τοποθετημένο στην επιφάνεια της κεφαλής λόγω της μεγάλης απόστασης. Ωστόσο, επειδή τα ηλεκτρόδια ανιχνεύουν το άθροισμα των δυναμικών στην περιοχή τους, τα δίπολα από πολλαπλούς νευρώνες σε μια περιοχή θα αθροιστούν μαζί. Το άθροισμα πολλών μεμονωμένων διπόλων σε μια περιοχή μετράται ως ένα μόνο δίπολο και η τιμή του αντανακλά τον αριθμό των νευρώνων των οποίων τα δίπολα αθροίζονται. Καθώς τα ηλεκτρόδια θα μετρήσουν το άθροισμα τόσο αρνητικών όσο και θετικών άκρων των διπόλων νευρώνων, προκειμένου να παραχθεί ένα μετρήσιμο (μη μηδενικό) σήμα, οι νευρώνες πρέπει να είναι ταυτόχρονα διατεταγμένοι με παράλληλο τρόπο και συγχρονισμένα διεγερμένοι [4]. Η παράλληλη διάταξη είναι απαραίτητη γιατί όταν οι νευρώνες είναι όλοι παρατεταγμένοι στον ίδιο προσανατολισμό, τότε τα σήματα τους μπορούν να αθροιστούν για να σχηματίσουν το μέγιστο σήμα. Σε διαφορετική περίπτωση, είναι πιθανό δίπολα να αθροιστούν και να αλληλοακυρωθούν. Επιπλέον, ο συγχρονισμός της δραστηριότητας είναι απαραίτητος ώστε το σήμα που θα παραχθεί να είναι μετρήσιμο, δηλαδή αρκετά μεγάλο. Τέλος, είναι αναγκαίο να γίνει λόγος για την αγωγιμότητα όγκου (volume conduction) η οποία είναι υπεύθυνη για την διάδοση του σήματος HEΓ μέσα στον εγκέφαλο. Πιο συγκεκριμένα, είναι η διαδικασία με την οποία μια δεξαμενή ιόντων απωθεί τα κοντινά ιόντα του ίδιου φορτίου. Αυτά τα απωθημένα ιόντα με τη σειρά τους απωθούν άλλα ιόντα του ίδιου φορτίου, με αποτέλεσμα ένα 'κύμα' φορτίου να ταξιδεύει δια μέσου του εξωκυττάριου χώρου [4].

Ο αριθμός των αγώγιμων ηλεκτροδίων που χρησιμοποιούνται κατά το HEΓ κυμαίνεται από 14 έως 256 και κάθε ηλεκτρόδιο αποτελεί ένα κανάλι. Γι' αυτό, το HEΓ αποτελεί ένα πολυκαναλικό σήμα.

Η τοποθέτησή τους στο κρανίο γίνεται με βάση το international system 10-20, το οποίο αποτελεί παγκόσμια αποδεκτό σύστημα που καθορίζει την θέση τοποθέτησης των ηλεκτροδίων. Πρακτικά, κάθε ηλεκτρόδιο έχει συγκεκριμένο όνομα και τοποθετείται στην ανάλογη θέση που καθορίζεται από το προαναφερθέν σύστημα, όπως φαίνεται στο Σχήμα 2.4. Πιο συγκεκριμένα, το όνομα περιλαμβάνει ένα γράμμα, το οποίο καταδεικνύει τον λοβό του εγκεφάλου όπου τοποθετείται το ηλεκτρόδιο, και έναν αριθμό ή ένα άλλο γράμμα που δείχνει την ημισφαιρική θέση τοποθέτησής του [7]. Το σχήμα 2.4 (a) περιέχει μικρότερο αριθμό ηλεκτροδίων, ενώ το σχήμα στα 2.4 (b) συμπεριλαμβάνει τις θέσεις περισσότερων.




Σχήμα 2.4: International system 10-20

Πρακτικά, η μέτρηση σε κάθε σημείο του κρανίου, στο οποίο έχει τοποθετηθεί το ηλεκτρόδιο, γίνεται ως προς ένα άλλο σημείο, το οποίο ονομάζεται σημείο αναφοράς. Δηλαδή, πραγματοποιείται συνεχής μέτρηση της διαφοράς δυναμικού μεταξύ των δύο σημείων και το μετρούμενο αποτέλεσμα αποτελεί το ηλεκτρικό σήμα που καταγράφεται στο συγκεκριμένο κανάλι. Το σημείο αναφοράς μπορεί να είναι κοινό για όλα τα ηλεκτρόδια (referential montage) ή διαφορετικό (bipolar montage). Στην περίπτωση που είναι κοινό μπορεί να είναι κάποιο συγκεκριμένο ηλεκτρόδιο ή να είναι η μέση τιμή των μετρήσεων των λοιπών ηλεκτροδίων.

Τα ηλεκτρικά σήματα που συλλέγονται με τη χρήση του ηλεκτροεγκεφαλογράφου κατά τη διάρκεια μιας εγκεφαλικής δραστηριότητας συνήθως απεικονίζονται στην οθόνη κάποιου υπολογιστή με τη βοήθεια κάποιου λογισμικού. Μια απεικόνιση της διαδικασίας καταγραφής της εγκεφαλικής δραστηριότητας με τοποθέτηση αγώγιμων ηλεκτροδίων στο τριχωτό της κεφαλής και της μορφής των ηλεκτρικών σημάτων συγκεκριμένων καναλιών παρουσιάζεται στο Σχήμα 2.5 [8].

Ένα βασικό πλεονεκτήματα του ΗΕΓ σε σύγκριση με άλλες τεχνικές απεικόνισης εγκεφάλου (όπως η λειτουργική απεικόνιση μαγνητικού συντονισμού) είναι ότι έχει πολύ υψηλή χρονική ανάλυση (υψηλή ανάλυση, δηλαδή, στο πεδίο του χρόνου). Πιο συγκεκριμένα, δίνει τη δυνατότητα παρακολούθησης συμβάντων εντός του εγκεφάλου με ακρίβεια 100 χιλιοστών του δευτερολέπτου (100 msec). Ωστόσο, σε σύγχρονα συστήματα η διακριτική ικανότητα στο πεδίο του χρόνου μπορεί να φτάσει και τα 4 msec. Επιπλέον, αξίζει να αναφερθεί ότι ο ηλεκτροεγκεφαλογράφος, δηλαδή η συσκευή που χρησιμοποιείται για την πραγματοποίηση του ηλεκτροεγκεφαλογράφηματος, είναι φορητή,



Σχήμα 2.5: Καταγραφή ΗΕΓ μέσω ηλεκτροδίων τοποθετημένων στο κρανίο του ατόμου

γεγονός που επιτρέπει την πραγματοποίηση νευροαπεικόνισης σε πραγματικό κόσμο εκτός κλινικού και εργαστηριακού περιβάλλοντος. Γι' αυτό, είναι μια πολύ ευρέως χρησιμοποιούμενη μέθοδος για εφαρμογές υγείας και ευεξίας, αλλά και διεπαφές εγκεφάλου-υπολογιστή [9].

Τα σήματα που συλλέγονται κατά τη διάρκεια ενός ΗΕΓ αποτελούν υπέρθεση τριών επιμέρους κατηγοριών, οι οποίες είναι οι εξής:

- οι Εγκεφαλικοί Ρυθμοί, που αποτελούν τη φυσιολογική δραστηριότητα
- τα Σήματα Μη Εγκεφαλικής Προέλευσης (artifacts), που είναι μη επιθυμητά και λογίζονται ως θόρυβος γιατί παραμορφώνουν το τελικό σήμα
- τα Προκλητά Δυναμικά (event related potentials), που αποτελούν φυσιολογική δραστηριότητα και παρουσιάζονται όταν εμφανίζεται κάποιο εξωτερικό ερέθισμα


2.3.1 Εγκεφαλικοί Ρυθμοί

Τα εγκεφαλικά σήματα φυσιολογικής δραστηριότητας που συλλέγονται κατά την πραγματοποίηση ενός ΗΕΓ έχουν συγκεκριμένα χαρακτηριστικά, κύρια από τα οποία είναι η συχνότητα και το πλάτος τους, η μορφή τους, καθώς και η συσχέτισή τους με φυσιολογικές διαδικασίες ή σε ορισμένες περιπτώσεις με παθολογικές.

Οι κυμάνσεις των σημάτων που τελικά συλλέγονται κατά το ΗΕΓ περιέχουν συγκεκριμένους ρυθμούς. Τα σήματα αυτά, δηλαδή, είναι ουσιαστικά υπέρθεση απλούστερων κυματομορφών με συγκεκριμένο πλάτος, συγκεκριμένο φασματικό περιεχόμενο και συγκεκριμένη κατανομή πάνω στον εγκέφαλο. Οι απλούστερες αυτές κυματομορφές ονομάζονται εγκεφαλικοί ρυθμοί και παρουσιάζονται παρακάτω:

- Ρυθμός Δέλτα (δ): Αποτελεί τον πιο αργό ρυθμό και κυμαίνεται μεταξύ 1 και 4 Hz. Επιπλέον, αποτελεί τον ρυθμό με το μεγαλύτερο πλάτος και εμφανίζεται σε νεογνά και ενήλικες κατά τη διάρκεια του ύπνου. Σχετίζεται με με γνωστικές και συναισθηματικές λειτουργίες, αλλά και με πολλές παθολογικές καταστάσεις.
- Ρυθμός Θήτα (θ): Αποτελεί τον δεύτερο πιο αργό ρυθμό μετά τον δ καθώς κυμαίνεται μεταξύ 4 και 8 Hz. Παρουσιάζεται ιδιαίτερα συχνά σε μικρά παιδιά και βρέφη και η παρουσία του μειώνεται με την πάροδο της ηλικίας. Αντανακλά την κατάσταση ανάμεσα στον ύπνο και στην εγρήγορση. Γενικά, σχετίζεται με το υποσυνείδητο καθώς και με τη δημιουργικότητα, τη διαίσθηση και την ονειροπόληση.
- Ρυθμός Άλφα (α): Κυμαίνεται μεταξύ 8 και 13 Hz, αποτελεί τον ρυθμό που υπερτερεί σε καταστάσεις ηρεμίας σε υγιείς ενήλικες. Φαίνεται καλύτερα όταν τα μάτια είναι κλειστά.
- Ρυθμός Βήτα (β): Κυμαίνεται μεταξύ 13 και 30 Hz και αποτελεί μαζί με το ρυθμό α τους δύο φυσιολογικούς ρυθμούς που παρατηρούνται σε ενήλικες σε κατάσταση εγρήγορσης. Υπερτερεί σε καταστάσεις έντασης, ανησυχίας και άγχους, ενώ έχει βρεθεί πως σχετίζεται με καταστάσεις έντονης συγκέντρωσης αλλά και με την επεξεργασία πληροφορίας και την λήψη αποφάσεων. Απουσία αυτού του ρυθμού υποδεικνύει μη φυσιολογικό φαινόμενο, ακόμη και στις μικρές ηλικίες.

Μια απεικόνιση της μορφής των αναφερθέντων ρυθμών παρουσιάζεται στο Σχήμα 2.6 [10].



Σχήμα 2.6: Εγκεφαλικοί ρυθμοί

2.3.2 Σήματα Μη Εγκεφαλικής Προέλευσης - Artifacts

Τα σήματα μη εγκεφαλικής προέλευσης που καταγράφονται στο ΗΕΓ ονομάζονται artifacts και μπορούν να χωριστούν σε δύο κατηγορίες, σ' αυτά που προέρχονται από πηγές εσωτερικά του υποκειμένου (σωματικά) και σ' αυτά που προέρχονται από εξωτερικές πηγές (εξωσωματικά). Είναι σημαντικό να επισημανθεί ότι τα εσωτερικά μπορεί να δημιουργούνται από το ίδιο το υποκείμενο αλλά δεν αποτελούν εγκεφαλική δραστηριότητα. Αντίθετα, τα εξωσωματικά αφορούν κυρίως θόρυβο που προκαλείται από το περιβάλλον ή από τον ίδιο τον εξοπλισμό. Παρακάτω περιγράφονται επιγραμματικά μερικά από τα πιο κοινά artifacts των δύο επιμέρους κατηγοριών.

Σωματικά artifacts

- Artifact προκαλούμενο από το ανοιγοκλείσιμο των ματιών (Eye Blink) : Εμφανίζεται στο ΗΕΓ ως κορυφές μεγάλου πλάτους και πολλές φορές το πλάτος αυτό είναι μεγαλύτερο από τα εγκεφαλικά σήματα ενδιαφέροντος. Επισημαίνεται πως και οι λοιπές κινήσεις των ματιών (Eye Movement) μπορούν να προκαλέσουν ανεπιθύμητα artifacts, αλλά διαφορετικής μορφής.
- Artifact προκαλούμενο από την ηλεκτρική δραστηριότητα που παράγεται κατά τις κινήσεις των μυών (Muscle Activity) που βρίσκονται κυρίως γύρω από την περιοχή του προσώπου και του αυχένα.
- Artifact προκαλούμενο από την ηλεκτρική δραστηριότητα που παράγεται κατά τον καρδιακό παλμό (Pulse).


Εξωσωματικά artifacts

- Σήμα γραμμής (power line interference): Εκφράζεται ως υψηλή ισχύ σε συγκεκριμένες συχνότητες (50 ή 60 Hz) που εμφανίζεται από το δίκτυο ηλεκτρικής ενέργειας και οφείλεται συνήθως σε ελαττωματικά καλώδια ή κακή επαφή με το κρανίο. Είναι εύκολο να εξαλειφθεί με την χρήση ενός χαμηλοπερατού φίλτρου.
- Artifact χωρικής ή ηλεκτροστατικής προέλευσης που προκαλούνται για παράδειγμα από την κίνηση ενός ατόμου στο χώρο
- Παρεμβολές από ηλεκτρονικές συσκευές που μπορεί να προκαλέσουν υπερφόρτωση των ενισχυτών της συσκευής του ηλεκτροεγκεφαλογράφου ή εκτροπή των ακροδεκτών με αποτέλεσμα να καταστεί αδύνατη η λήψη σήματος.

Στο Σχήμα 2.7 απεικονίζεται η μορφή αυτών των πολύ συνηθισμένων artifacts [11].

2.3.3 Προκλητά δυναμικά - Event Related Potentials (ERPs)

Η ηλεκτρική δραστηριότητα του εγκεφάλου αποτελεί μια ατέρμονη διαδικασία, αφού λαμβάνει χώρα ακούσια διαρκώς. Ωστόσο, είναι δυνατόν να εμφανιστεί ως απόκριση σε κάποιο εξωτερικό ερέθισμα. Τα ηλεκτρικά δυναμικά που ανιχνεύονται μετά την εμφάνιση τέτοιων ερεθισμάτων μπορούν να διακριθούν από τα ακούσια δυναμικά που παράγονται στον εγκέφαλο και η μεταβολή που προκαλούν στην



Σχήμα 2.7: Μορφή διάφορων Artifacts

μορφή του ηλεκτροεγκεφαλογραφήματος ονομάζεται δυναμικό που σχετίζεται με κάποιο γεγονός (event related potential) ή, πιο απλά, προκλητό δυναμικό (evoked potential).

Το είδος του ερεθίσματος οδηγεί στη διάκριση των προκλητών δυναμικών σε:

1. Οπτικά προκλητά δυναμικά (Visual ERPs)
2. Ακουστικά προκλητά δυναμικά (Audio ERPs)
3. Σωματοαισθητικά προκλητά δυναμικά (Somatosensory ERPs)

Επιπλέον, ανάλογα με την χρονική διάρκεια του εξωτερικού ερεθίσματος που το προκάλεσε, το προκλητό δυναμικό μπορεί να είναι:

- παροδικό, όταν προκαλείται από ερέθισμα μικρής χρονικής διάρκειας,
- μόνιμο, όταν προκαλείται από συνεχές ερέθισμα, ή
- καθοδηγούμενο, όταν προκαλείται από ερέθισμα που επαναλαμβάνεται πολύ γρήγορα.


Γενικά, τα προκλητά δυναμικά τείνουν να είναι μικρά σε πλάτος, κυμαινόμενα από 1 μVolt , ή ενδεχομένως και λιγότερο, έως λίγα μVolts , ενώ οι εγκεφαλικοί ρυθμοί του ΗΕΓ εμφανίζουν πλάτος τουλάχιστον δεκάδων μVolts . Αυτά τα δυναμικά προκειμένου να διακριθούν από την υπόλοιπη ηλεκτροεγκεφαλική δραστηριότητα και από περιβαλλοντικούς θορύβους χρειάζεται να εξαχθεί ο μέσος όρος τους (averaging). Υπολογίζεται, δηλαδή, ο μέσος όρος (signal averaging) των σημάτων που παρατηρούνται κατά την επαναλαμβανόμενη έκθεση στο ίδιο αισθητηριακό ερέθισμα [12]. Χάρη σε αυτή τη μέθοδο καταστέλλεται ο θόρυβος, οποίος στην περίπτωση αυτή θεωρείται όλο το υπόλοιπο

σήμα εκτός από το ERP, και εντοπίζεται η 'καθαρή' απάντηση στο ερέθισμα (time-locked event).

Τα ERPs χωρίζονται σε δύο επιμέρους κατηγορίες, οι οποίες είναι:

- τα αισθητήρια ή εξωγενή, που εξαρτώνται από τις φυσικές παραμέτρους του ερεθίσματος και εμφανίζονται στα πρώτα 100 msec μετά την εμφάνιση του ερεθίσματος, και
- τα γνωστικά ή ενδογενή, που δημιουργούνται αργότερα και σχετίζονται με τον τρόπο αξιολόγησης του ερεθίσματος.

Μια μορφή του ERP που εντοπίζεται στον ινιακό λοβό (και συγκεκριμένα στο EEG κανάλι O1) και προκαλείται από οπτικά ερεθίσματα κατά τη διάρκεια μιας διαδικασίας διάκρισης στόχου ενός ατόμου, όσο αυτό παραμένει ακίνητο, παρουσιάζεται στο Σχήμα 2.8. Συγκεκριμένα, το παρουσιαζόμενο σήμα αποτελεί το μέσο σήμα στόχου (target ERP signal) ενός ατόμου που προέκυψε μέσω της διαδικασίας signal averaging, για την οποία έχει γίνει λόγος παραπάνω. Οι κορυφές και οι κοιλότητες της κυματομορφής θεωρείται πως επιτρέπει την οπτικοποίηση της γνωστικής επεξεργασίας του εγκεφάλου [13].



Σχήμα 2.8: average ERP ενός ατόμου για το ηλεκτρόδιο O1 (Ινιακός Λοβός)

2.4 Το Ηλεκτροεγκεφαλογράφημα από την περιοχή του αυτιού (ear-EEG)

Είναι σημαντικό να επισημανθεί πως ο τρόπος διεξαγωγής των ΗΕΓ ήταν, σε πρώτη φάση, ιδιαίτερα απαιτητικός ως προς την εκτέλεσή του και παρουσίαζε δυσκολίες. Ο ηλεκτροεγκεφαλογράφος αποτελούσε μια μεγάλη και ογκώδη τεχνολογία που περιοριζόταν στην παρακολούθηση ατόμων εντός ενός εργαστηρίου ή μιας κλινικής. Προκειμένου να μειώνονται κατά το δυνατόν οι εξωτερικές πηγές

θορύβου και να ανιχνεύονται με τον καλύτερο τρόπο τα ηλεκτρικά δυναμικά από την περιοχή του εγκεφάλου, τα άτομα ήταν αναγκαίο να παραμένουν ακίνητα καθόλη τη διάρκεια των πειραμάτων.

Ωστόσο, έχει εντοπιστεί ότι οι αποκρίσεις του εγκεφάλου που παρατηρούνται υπό συγκεκριμένες εργαστηριακές συνθήκες μπορεί να διαφέρουν από εκείνες που παρατηρούνται σε φυσικά περιβάλλοντα, όπως ένα περιβάλλον στο οποίο το υποκείμενο κινείται. Γι' αυτό, την τελευταία δεκαπενταετία έχει καταβληθεί μεγάλη ερευνητική προσπάθεια για τη δημιουργία φορητής τεχνολογίας EEG (wearable EEG) το οποίο ξεπερνά αυτούς τους περιορισμούς και να επιτρέπει τη μακροπρόθεσμη μη επεμβατική καταγραφή των εγκεφαλικών σημάτων ενώ οι άνθρωποι είναι έξω από το εργαστήριο και κινούνται [14]. Το wearable EEG είναι, με άλλα λόγια, μια τεχνολογία που επιτρέπει τη μετάφραση της νευροεπιστήμης από το εργαστήριο στο πραγματικό περιβάλλον της ζωής και έχει τη δυνατότητα να ανοίξει εντελώς νέες ευκαιρίες στον τομέα της έρευνας και των ιατροτεχνολογικών προϊόντων.

Μια νέα και πολλά υποσχόμενη wearable τεχνολογία EEG αποτελεί το ear-EEG. Πιο συγκεκριμένα, είναι μια μέθοδος καταγραφής στην οποία τα σήματα EEG ανιχνεύονται από ηλεκτρόδια που τοποθετούνται μέσα στην περιοχή του αυτιού ή γύρω από αυτό (συνήθως σχηματίζοντας ένα ημικόκλιο (cEEGGrid- Σχήμα 2.9) [15]. Σε σύγκριση με το συμβατικό EEG, το ear-EEG χρησιμοποιεί λιγότερα ηλεκτρόδια και καλύπτει μόνο ένα μικρό μέρος του κεφαλιού.



Σχήμα 2.9: Καταγραφή ear-EEG

Η τεχνολογία του ear-EEG παρέχει πληθώρα πλεονεκτημάτων. Το κύριο πλεονέκτημά της μεθόδου ear-EEG είναι πως υποστηρίζει μακροχρόνιες καταγραφές ΗΕΓ σε πραγματικό περιβάλλον [16]. Το σχήμα των συσκευών ear-EEG που χρησιμοποιούνται για μακροχρόνια παρακολούθηση είναι πολύ παρόμοιο με τα ακουστικά βαρηκοΐας, μιας και λόγω του μεγέθους της συσκευής μπορεί να φορεθεί χωρίς να παρεμβαίνει στις καθημερινές δραστηριότητες του ατόμου παρέχοντας διακριτικότητα και άνεση στον τρόπο καταγραφής [17]. Άλλα πλεονεκτήματα που υπόσχεται είναι η σταθερότητα στις θέσεις των ηλεκτροδίων, αλλά και η ανθεκτικότητα στις ηλεκτρομαγνητικές παρεμβολές. Τέλος, το σύστημα ear-EEG θα μπορούσε επίσης να υποστηρίξει πρόσθετους βιοαισθητήρες, επεκτείνοντας την εμβέλεια της πέρα από το ΗΕΓ, ώστε να παρέχει ένα ισχυρό σύστημα

παρακολούθησης της υγείας για εκείνες τις εφαρμογές που απαιτούν μεγάλες περιόδους καταγραφής σε φυσικό περιβάλλον [9].

Αξίζει να επισημανθεί ότι καταγραφές ear-EEG έχουν πραγματοποιηθεί με ηλεκτρόδια στα οποία εφαρμόστηκε αγωγίμο τζελ μεταξύ των ηλεκτροδίων και του δέρματος ώστε να βελτιωθεί η μεταξύ τους επαφή [18]. Ωστόσο, έχει ερευνηθεί και η δυνατότητα χρήσης ηλεκτροδίων ξηρής επαφής η οποία αυξάνει την άνεση και τη φιλικότητα προς το χρήστη και του επιτρέπει να εισάγει τη συσκευή χωρίς βοήθεια [17].

Κρίνεται απαραίτητο να επισημανθεί πως το ear-EEG θα είναι λιγότερο ευαίσθητο σε σήματα που παράγονται στον εγκεφαλικό φλοιό και περισσότερο ευαίσθητο στο θόρυβο, καθώς, όπως έχει ήδη αναφερθεί, χρησιμοποιεί λιγότερα ηλεκτρόδια και καλύπτει μόνο ένα μικρό μέρος του κεφαλιού. Με άλλα λόγια, αναμένεται κάποια απώλεια πληροφορίας συγκρίνοντας το ear-EEG με το EEG. Αξίζει να αναφερθεί ότι έχει βρεθεί πως το ear-EEG είναι πιο ευαίσθητο σε σήματα που παράγονται στον χροταφικό λοβό αφού τα ηλεκτρόδιά του τοποθετούνται κοντινότερα στον λοβό αυτό. Επομένως, θεωρείται πως απεικονίζει με μεγαλύτερη ακρίβεια την εγκεφαλική δραστηριότητα που πηγάζει την περιοχή αυτή. [19].

2.5 Κίνηση και Ηλεκτροεγκεφαλογράφημα

Η παρακολούθηση της εγκεφαλικής δραστηριότητας κατά τη διαδικασία κίνησης παρουσιάζει ιδιαίτερο ενδιαφέρον, καθώς επιτρέπει τη μετάβαση από το εργαστήριο στο πραγματικό περιβάλλον της ζωής. Είναι γεγονός ότι η απόκριση ενός υποκειμένου σε ένα εξωτερικό αισθητηριακό ερέθισμα εξαρτάται από την κατάσταση στην οποία βρίσκεται όταν δέχεται αυτό το ερέθισμα, όπως αποδεικνύεται από την δραματική μείωση της ανταπόκρισης κατά τη διάρκεια του ύπνου ή σε ορισμένες καταστάσεις αναισθησίας. Όσο το άτομο βρίσκεται σε εγρήγορση, η προσοχή που δίνει στο ερέθισμα μπορεί να επηρεάσει έντονα την αντιληπτική του ικανότητά σχετικά με αυτό [20]. Δεδομένου, λοιπόν, ότι η διαδικασία της κίνησης απαιτεί την παραγωγή σημάτων από την περιοχή του κινητικού φλοιού (motor cortex) επηρεάζοντας παράλληλα την προσοχή που δίνεται στο εξωτερικό ερέθισμα, αναμένεται να επηρεάσει και την τελική μορφή των παραγόμενων εγκεφαλικών σημάτων, διαφοροποιώντας την από την περίπτωση ακινησίας.

Επισημαίνεται ότι προηγούμενες μελέτες οπτικών προκλητών δυναμικών (visual evoked potentials) σε τρωκτικά έδειξαν ότι τα δυναμικά αυτά είναι σημαντικά διαφορετικά όταν αλλάζει η κινητική κατάστασή τους [21]. Οι περισσότεροι νευρώνες εμφάνισαν, κατά κύριο λόγο, διπλασιασμό στο πλάτος του οπτικά προκληθέντος δυναμικού όσο το τρωκτικό περνούσε από την ακινησία στο τρέξιμο. Πιο συγκεκριμένα, σε περιόδους που το τρωκτικό ήταν ακίνητο, παρατηρούνταν ευρεία ζώνη ισχύος σε χαμηλές συχνότητες συμπεριλαμβανοντας μια κορυφή μεταξύ 10 - 30 Hz και μια κορυφή μικρής διάρκειας στην περιοχή γ, και συγκεκριμένα στα 50 - 70 Hz που διέφερε για κάθε ζώο. Η κίνηση συσχετίστηκε με μείωση της ισχύος χαμηλής συχνότητας και δραματική αύξηση του πλάτους της κορυφής γ υψηλής συχνότητας.

Είναι πιθανόν, λοιπόν, πως έντονες διαφοροποιήσεις στα εγκεφαλικά παραγόμενα σήματα θα έχουμε και στην περίπτωση της κίνησης και ακινησίας ανθρώπων. Με την εκπόνηση της παρούσας διπλωματικής, θα επιδιωχθεί να αποδειχθεί πως είναι εφικτή η διάκριση των σημάτων που παρατηρούνται κατά την αλλαγή της κινητικής κατάστασης των ατόμων.

2.5.1 Moving artifacts στο EEG

Μερικές πρόσφατες μελέτες έχουν χρησιμοποιήσει ΗΕΓ για να χαρακτηρίζουν την εγκεφαλική δραστηριότητα ενώ το άτομο περπατά. Όμως, η διάκριση του artifact που εντοπίζεται λόγω της κίνησης (moving artifact), από το 'καθαρό' πραγματικό σήμα που απεικονίζει την ηλεκτροεγκεφαλική δραστηριότητα είναι πολύ δύσκολο να υλοποιηθεί, μιας και τα artifacts κίνησης δεν μπορούν να εξηγηθούν από τις επιταχύνσεις του κεφαλιού και ποικίλλουν ανάλογα με την ταχύτητα κίνησης, το άτομο και το κανάλι [22].

Έχουν γίνει διάφορες προσπάθειες αφαίρεσης των artifacts κίνησης. Ωστόσο, ευρέως χρησιμοποιούμενες τεχνικές τυφλού διαχωρισμού (Blind Source Separation techniques) όπως η μέθοδος ανάλυσης ανεξάρτητων κυρίαρχων συνιστωσών (Independent Component Analysis) και η μέθοδος ανάλυσης κανονικοποιημένης συσχέτισης (Canonical Correlation Analysis) [23] είναι πολύ αποτελεσματικές για τον διαχωρισμό των artifacts που παράγονται από την κίνηση των ματιών (eye movement artifacts) [24] και των μυών (muscle artifacts) από τα σήματα εγκεφαλικής δραστηριότητας, αλλά είναι λιγότερο αποτελεσματικές στην αφαίρεση των moving artifacts λόγω της έλλειψης ανεξαρτησίας μεταξύ τους.

Αν μπορούσαμε να προσδιορίσουμε ρητά τις φασματικές και χρονικές ιδιότητες του artifact κίνησης, αυτό θα μπορούσε να εντοπιστεί και να αφαιρεθεί, διατηρώντας το επιθυμητό σήμα EEG που προκύπτει κατά τη διαδικασία κίνησης. Ωστόσο, έχει βρεθεί ότι τα artifacts κίνησης που εμφανίζονται όσο ένα άτομο περπατάει έχουν μεγάλες φασματικές διακυμάνσεις κατά τη διαδικασία βάρδισης που αυξάνονται σε πλάτος όσο η ταχύτητα κίνησης αυξάνεται [22]. Επιπλέον, κατά την αύξηση της ταχύτητας, οι φασματικές αυτές διακυμάνσεις εμφανίζονται σε ζώνες υψηλότερης συχνότητας. Αξίζει, ακόμη, να επισημανθεί πως η μορφή των moving artifacts διαφέρει σημαντικά μεταξύ των υποκειμένων και μεταξύ της θέσης τοποθέτησης των ηλεκτροδίων, δηλαδή μεταξύ των διαφορετικών καναλιών του ηλεκτροεγκεφαλογραφήματος.

Παρά το γεγονός πως συνήθως επιδιώκεται η αφαίρεση των artifacts κίνησης, κατά την εκπόνηση της παρούσας διπλωματικής έχει γίνει μια προσπάθεια να αξιοποιηθεί ο θεωρούμενος θόρυβος των moving artifacts, προκειμένου να αποδειχτεί πως είναι εφικτή η ταξινόμηση των ear-EEG σημάτων βάσει της κινητικής κατάστασης των ατόμων. Με άλλα λόγια, επιδιώκεται να γίνει η διάκριση της κινητικής κατάστασης με ταυτόχρονη εκμετάλλευση της παράλληλης αλλαγής της μορφής του καθαρού EEG σήματος και του moving artifact σε κάθε σενάριο κίνησης με δεδομένη ταχύτητα.

Κεφάλαιο 3

Θεωρητικό Υπόβαθρο

3.1 Αποσύνθεση Σμήνους - (Swarm Decomposition - SWD)

Η Ευφυΐα Σμήνους (Swarm Intelligence) είναι ένας κλάδος της Τεχνητής Νοημοσύνης που εμπνέεται από τη συλλογική συμπεριφορά φυσικών κοινωνικών ομάδων, όπως για παράδειγμα οι μέλισσες, τα μυρμήγκια και τα πουλιά. Πιο συγκεκριμένα, περιλαμβάνει τη μελέτη συστημάτων που αποτελούνται από πολλαπλούς αλληλοεξαρτώμενους και αλληλεπιδρώντες παράγοντες που συνεργάζονται με σκοπό την επίτευξη ενός κοινού στόχου. Οι απομονωμένοι παράγοντες είναι συχνά απλοί και δεν παρουσιάζουν υψηλή νοημοσύνη, αλλά η συλλογική συμπεριφορά όλου του συνόλου του σμήνους μπορεί να είναι εξαιρετικά έξυπνη και να ικανή να επιλύσει σοβαρά προβλήματα. Οι αλγόριθμοι ευφυΐας σμήνους βασίζονται στις αρχές της αυτοοργάνωσης και της ομαδοποίησης, και μπορούν να χρησιμοποιηθούν για την επίλυση ενός ευρέος φάσματος προβλημάτων λήψης αποφάσεων και βελτιστοποίησης.

Η Αποσύνθεση Σμήνους (Swarm Decomposition- SWD) είναι βασισμένη στην ευφυΐα σμήνους και αποτελεί μια καινοτόμο προσέγγιση για την αποσύνθεση μη-στάσιμων σημάτων [25]. Ο πυρήνας της ανάλυσης ενός μη-στάσιμου σήματος είναι η αποσύνθεση του αρχικού μη-στάσιμου σήματος στις επιμέρους συνιστώσες του (components), τα οποία είναι εντοπισμένα τόσο σε χρόνο όσο και σε συχνότητα. Οι μέθοδοι ανάλυσης των μη-στάσιμων σημάτων ταξινομούνται σε αυτές που λαμβάνουν υπόψιν την ατομική αποσύνθεση και τις κατανομές ενέργειας, οι οποίες αποκαλούνται τετραγωνικές παραστάσεις χρόνου-συχνότητας. Μία αξιοσημείωτη μέθοδο αποτελεί η αποσύνθεση EMD (empirical mode decomposition)), στην οποία οι συνιστώσες του σήματος, αποφασίζονται εκ των υστέρων (a posteriori) διατηρώντας την φυσική έννοια της αποσύνθεσης σε μη στάσιμες και μη γραμμικές περιπτώσεις. Η Αποσύνθεση Σμήνους αποτελεί μια μέθοδο ατομικής αποσύνθεσης, όπου οι συνιστώσες του σήματος προκύπτουν a posteriori. Με τη χρήση του επιδιώκεται η εκμετάλλευση των πλεονεκτημάτων της αποσύνθεσης EMD με ταυτόχρονη χρήση μιας αυστηρής μαθηματικής μεθοδολογίας, και όχι εμπειρικής.

Η αποσύνθεση σμήνους υλοποιείται με χρήση του λεγόμενου φιλτραρίσματος σμήνους (Swarm Filtering), το οποίο αποτελεί έναν αλγόριθμο επεξεργασίας διακριτών στο χρόνο σημάτων, βασισμένο στο κυνήγι σμήνους-θύματος (swarm-prey hunting). Πιο συγκεκριμένα, η αποσύνθεση σμήνους πραγματοποιείται εφαρμόζοντας επαναληπτικά φιλτραρίσματα σμήνους, όπου σε κάθε επανάληψη, με κατάλληλη παραμετροποίηση, η έξοδος του φίλτρου έχει ως αποτέλεσμα την παραγωγή μιας μεμονωμένης συνιστώσας του σήματος εισόδου, η οποία ονομάζεται oscillatory mode (OM).

Οι σχέσεις μεταξύ των παραμέτρων και των αποκρίσεων μετά το φιλτράρισμα εξάγονται με χρήση ενός γενετικού αλγορίθμου (genetic algorithm).

Περιγραφή της μεθόδου

Η Αποσύνθεση Σμήνους βασίζεται στην σωστή παραμετροποίηση του Φιλτραρίσματος Σμήνους, προκειμένου να εξαχθούν οι συχνοτικές συνιστώσες (OCs) του πολυσυχνοτικού μη-στάσιμου σήματος εισόδου $s[n]$, $\forall n = 0, \dots, L - 1$. Συγκεκριμένα, η αποσύνθεση σμήνους αποτελείται από μια επαναληπτική εκτέλεση μιας διαδικασίας ολίσθησης, όπου σε κάθε επανάληψη, εικάζεται αρχικά η κυρίαρχη συνιστώσα OC και στη συνέχεια λαμβάνεται από επαναλαμβανόμενες εφαρμογές του φιλτραρίσματος σμήνους. Έπειτα, μετά τον υπολογισμό της, η συχνοτική συνιστώσα, αφαιρείται από το αρχικό σήμα εισόδου. Η διαδικασία τερματίζεται όταν το σήμα εισόδου που παραμένει δεν περιλαμβάνει καμιά συχνοτική συνιστώσα με επαρκή ενέργεια.

Ας υποθέσουμε ότι $x[n]$ είναι η ακολουθία κατά την i -οστή επανάληψη της διαδικασίας ολίσθησης και ω_{dom}^q είναι η συχνότητα που υποθέτεται πως είναι η κυρίαρχη συχνοτική συνιστώσα της $x_i[n]$. Μια συχνοτική συνιστώσα μπορεί να ταυτοποιηθεί ως κυρίαρχη σε πολλές επαναλήψεις ολίσθησης και γι' αυτό χρησιμοποιείται ο δείκτης q , υποδηλώνοντας την q -οστή αναγνώριση αυτής της συχνότητας κατά τη διαδικασία αποσύνθεσης. Ακόμη, η συχνότητα ω_{dom}^q ορίζεται ως αυτή με την μέγιστη φασματική πυκνότητα ενέργειας. Πολύ σημαντική είναι η εξομάλυνση (smoothing) του φάσματος ενέργειας προτού βρεθούν οι υψηλότερες κορυφές της, έτσι ώστε να αποφευχθεί η δημιουργία artifacts. Έτσι, για την επίτευξη εξομάλυνσης του φάσματος ενέργειας χρησιμοποιείται το φίλτρο του Welch. Υπάρχουν τέσσερις βασικές και απαραίτητες παράμετροι που απαιτούνται για το φιλτράρισμα, και αυτές είναι το κατώφλι της επιλογής κορυφών (P_{th}), το παράθυρο του φίλτρου (welch window), ο δείκτης επικάλυψης φίλτρου (welch overlap) και ο αριθμός των διακριτών σημείων του μετασχηματισμού Fourier (welch nfft) για τον υπολογισμό της φασματικής πυκνότητας ισχύος. Μετά από επιλογή των παραπάνω παραμέτρων υπολογίζεται η κυρίαρχη συνιστώσα ω_{dom}^q από τις ακόλουθες σχέσεις:

$$\begin{aligned}\omega_{dom}^q &= \operatorname{argmax}(S'_{xi}(\omega) > P_{th}), \\ S'_{xi}(\omega) &= \operatorname{WelchFilter}(S_{xi}(\omega))\end{aligned}\tag{3.1}$$

Αξίζει να σημειωθεί ότι η παράμετρος P_{th} παίρνει, συνήθως, τιμές κοντά στο 0.1 και επηρεάζει τον αριθμό των τελικών συνιστωσών OMs που θα παραχθούν στο τέλος της διαδικασίας. Μεγαλύτερες τιμές της παραμέτρου έχουν ως αποτέλεσμα την δημιουργία ενός μικρού τελικά παραγώμενου αριθμού OMs, ενώ μικρότερες οδηγούν στη δημιουργία περισσότερων OMs.

Αφού γίνει ο υπολογισμός της κυρίαρχης συχνότητας υπολογίζεται ο αριθμός των μελών του σμήνους (M) και η παράμετρος δ , που ρυθμίζει την ευελιξία του σμήνους βάσει των σχέσεων:

$$\begin{aligned}M(\hat{\omega}) &= 33.46\hat{\omega}^{-0.735} - 29.1 \\ \delta(\hat{\omega}) &= -1.5\hat{\omega}^2 + 3.454\hat{\omega} - 0.01\end{aligned}\tag{3.2}$$

όπου $\hat{\omega}$ η κανονικοποιημένη συχνότητα.

Η επαναλαμβανόμενη εκτέλεση του Φιλτραρίσματος Σμήνους (Swarm Filtering) έχει ως αποτέλεσμα τον εντοπισμό των συχνοτικών συνιστωσών του σήματος εισόδου. Ο αλγόριθμος τερματίζεται όταν το αποτέλεσμα δύο διαδοχικών επαναλήψεων αποκλίνει λιγότερο από ένα κατώφλι (StD_{th}),

το οποίο, συνήθως, παίρνει μια μικρή τιμή (για παράδειγμα την τιμή 0.1). Συνοψίζοντας, οι μόνες παράμετροι που εμπλέκονται στο Φιλτράρισμα Σμήνους είναι οι παράμετροι σμήνους M και δ και το κατώφλι StD_{th} . Στο Σχήμα 3.1 [25] παρουσιάζονται τα βήματα του αλγορίθμου (Algorithm 1) που ακολουθείται για την υλοποίηση του Φιλτραρίσματος Σμήνους.

Algorithm 1. Iterative SwF.


```

1: procedure ITERATIVESWF  $x_{it}[n], M, \delta, StD_{th}$ 
2:    $x[n] \leftarrow x_{it}[n]$ 
3:    $y_0[n] \leftarrow x$ 
4:    $j \leftarrow 0$ 
5:   repeat
6:      $j \leftarrow j + 1$ 
7:      $y_j[n] \leftarrow SwF(x[n], M, \delta)$ 
8:      $x[n] \leftarrow y_j[n]$ 
9:      $StD \leftarrow \sum_n \frac{|y_j[n] - y_{j-1}[n]|^2}{y_{j-1}[n]^2}$ 
10:  until  $StD < StD_{th}$ 
11:  return  $x'_{it}[n] \leftarrow y_j[n]$ 
12: end procedure

```

Σχήμα 3.1: Φιλτράρισμα Σμήνους

Ακόμη, στο Σχήμα 3.2 [25] παρουσιάζεται ένα παράδειγμα αποσύνθεσης ενός μη-στάσιμου αρχικού σήματος (multi-component signal) σε επιμέρους συνιστώσες (mono-component), στα λεγόμενα OMs.



Σχήμα 3.2: Αποσύνθεση Σμήνους

3.2 Μηχανική Μάθηση

Η Μηχανική Μάθηση (Machine Learning - ML) είναι ένας κλάδος της Τεχνητής Νοημοσύνης (Artificial Intelligence - AI) που είναι στενά συνδεδεμένος με πολλούς άλλους επιστημονικούς κλάδους [26]. Τέτοιοι κλάδοι είναι της Επιστήμης Υπολογιστών, των Πιθανοτήτων Στατιστικής, της Θεωρίας Βελτιστοποίησης, αλλά και της Αναγνώρισης Προτύπων. Αντικείμενο της μηχανικής μάθησης είναι το φαινόμενο κατά το οποίο ένα σύστημα βελτιώνει την απόδοσή του κατά την εκτέλεση μιας συγκεκριμένης εργασίας μέσω της αξιοποίησης προηγούμενης γνώσης και εμπειρίας, χωρίς, όμως, να είναι ρητά προγραμματισμένο να το κάνει. Οι αλγόριθμοι μηχανικής μάθησης είναι σε θέση να εντοπίζουν μοτίβα στα δεδομένα και να μαθαίνουν από αυτά, προκειμένου να κάνουν τις δικές τους προβλέψεις. Με άλλα λόγια, χρησιμοποιούν ιστορικά δεδομένα ως είσοδο για να προβλέψουν νέες τιμές εξόδου. Μαθαίνουν, δηλαδή, και βελτιώνουν την απόδοσή τους μέσω της εμπειρίας.

Κατηγορίες Μηχανικής Μάθησης

Υπάρχουν τρεις κύριες προσεγγίσεις στη μηχανική μάθηση, οι οποίες είναι η εποπτευόμενη (supervised learning), η χωρίς επίβλεψη (unsupervised learning) και η ενισχυτική μάθηση (reinforcement learning). Επιπλέον, υπάρχουν και υβριδικές προσεγγίσεις, συμπεριλαμβανομένης της ημι-επιβλεπόμενης μάθησης (semi-supervised learning), η οποία αποτελεί έναν συνδυασμό εποπτευόμενης με μη-εποπτευόμενη μάθηση και μπορεί να προσαρμοστεί στο πρόβλημα που επιδιώκει να λύσει ένας ερευνητής. Κάθε προσέγγιση έχει συγκεκριμένα πλεονεκτήματα και μειονεκτήματα και ορισμένες τεχνικές ταιριάζουν καλύτερα σε συγκεκριμένους τύπους προβλημάτων από άλλες.

Στην εποπτευόμενη μάθηση, γίνεται εκπαίδευση σε ένα σύνολο εισόδων και εξόδων δεδομένων τα οποία είναι επισημασμένα με ετικέτες (labels), με στόχο την εκμάθηση ενός γενικού κανόνα που αντιστοιχίζει τις δεδομένες εισόδους στις δεδομένες εξόδους [27]. Οι πιο κοινές τεχνικές επιβλεπόμενης μάθησης είναι η ταξινόμηση (classification) και η παλίνδρομηση (regression).

Στην μη-επιβλεπόμενη μάθηση, τα δεδομένα που δίνονται δεν είναι επισημασμένα με μια ετικέτα, δεν υπάρχει δηλαδή τιμή εξόδου για μια συγκεκριμένη είσοδο, αλλά ο υπολογιστής καλείται να ανακαλύψει μόνος του το μοτίβο ή τη δομή της. Η συγκεκριμένη διαδικασία χρησιμοποιείται ευρέως για την εξαγωγή γενετικών χαρακτηριστικών, τον προσδιορισμό και την ομαδοποίηση σημαντικών τάσεων από ένα σύνολο δεδομένων [28]. Δύο κύριοι τύποι μη-επιβλεπόμενης μάθησης είναι η ομαδοποίηση (clustering), η οποία περιλαμβάνει την ανακάλυψη ομάδων εντός του συνόλου δεδομένων που μοιράζονται παρόμοια χαρακτηριστικά, και η εκτίμηση της πυκνότητας (density estimation), η οποία περιλαμβάνει την αξιολόγηση της στατιστικής κατανομής του συνόλου δεδομένων.

Στην ενισχυτική μάθηση, ο υπολογιστής θα αντιμετωπίσει ένα πρόβλημα σε ένα δυναμικό περιβάλλον και, καθώς εργάζεται για την επίτευξη ενός δεδομένου στόχου, θα λάβει ανατροφοδότηση (ανταμοιβές όταν η δράση συμβάλλει στην εφαρμογή του στόχου, ή αντίστροφα κυρώσεις όταν κινείται προς την αντίθετη κατεύθυνση), που θα ενισχύσουν την προσπάθεια μάθησης και αναζήτησης στόχων [29]. Σκοπός των αλγορίθμων είναι η μεγιστοποίηση της αμοιβής και η ελαχιστοποίηση της κύρωσης. Δύο ευρέως χρησιμοποιούμενοι αλγόριθμοι ενισχυτικής μάθησης είναι ο (Q-learning) και η μάθηση με χρονικές διαφορές (Temporal difference learning).

Στο σημείο αυτό είναι χρήσιμο να επισημανθεί πως στον πραγματικό κόσμο τα σύνολα δεδομένων μη επισημασμένα με ετικέτες είναι πολυάριθμα, ενώ τα επισημασμένα με ετικέτες σπανίζουν.

Για το λόγο αυτό η ημι-επιβλεπόμενη μάθηση θεωρείται ιδιαίτερα χρήσιμη, μιας και απώτερος στόχος της είναι η παροχή ενός ακριβέστερου αποτελέσματος για την πρόβλεψη των δεδομένων εξόδου σε σχέση με αυτό ενός μοντέλου που χρησιμοποιεί μόνο τα επισημασμένα με ετικέτες δεδομένα, εκμεταλλευόμενο και μη-επισημασμένα.

Σχεδιασμός ενός συστήματος Μηχανικής Μάθησης


Τα στάδια που ακολουθούνται κατά τον σχεδιασμό ενός συστήματος μηχανικής μάθησης είναι κοινά, ανεξάρτητα από το μοντέλο που θα χρησιμοποιηθεί, και είναι τα εξής [30]:

1. η συλλογή των δεδομένων (training of the data)
2. η προεπεξεργασία τους (preprocessing)
3. η επιλογή ενός μοντέλου (model selection)
4. η εκπαίδευσή του (model training)
5. η αξιολόγησή του (model evaluation)
6. ο συντονισμός των παραμέτρων του (parameter tuning)
7. η πραγματοποίηση προβλέψεων (generation of predictions)

Παρακάτω, παρέχονται περισσότερες λεπτομέρειες για τα στάδια αυτά.

Η συλλογή των δεδομένων μπορεί να γίνει από διάφορες πηγές, όπως ένα αρχείο, μια βάση δεδομένων, αισθητήρες και πολλές άλλες. Τα δεδομένα, όμως, που συλλέγονται δεν μπορούν να χρησιμοποιηθούν απευθείας για την εκτέλεση της διαδικασίας ανάλυσης, καθώς ενδέχεται να παρουσιάζονται απώλειες, να παρουσιάζουν εξαιρετικά υψηλές τιμές, να είναι μη οργανωμένα ή να είναι θορυβώδη. Γι' αυτό, εκτελούνται ορισμένα βήματα για τη μετατροπή των δεδομένων σε ένα μικρό καθαρό σύνολο δεδομένων και αυτό το μέρος της διαδικασίας ονομάζεται προεπεξεργασία δεδομένων (preprocessing). Στη συνέχεια απαιτείται επιλογή του μοντέλου (model selection) που ταιριάζει καλύτερα στο είδος των δεδομένων.

Για την εκπαίδευση του μοντέλου αυτού πραγματοποιείται χωρισμός των δεδομένων σε τρία υποσύνολα, τα δεδομένα εκπαίδευσης (training set), τα δεδομένα επικύρωσης (validation set) και τα δεδομένα δοκιμής (test set). Το μοντέλο προσαρμόζεται στο σύνολο δεδομένων εκπαίδευσης, δηλαδή στην πράξη, εκπαιδεύεται να παρέχει την επιθυμητή έξοδο για κάθε είσοδο του συνόλου. Έπειτα, το εκπαιδευμένο (ή προσαρμοσμένο), πλέον, μοντέλο χρησιμοποιείται για την παροχή προβλέψεων σε παρατηρήσεις από το σύνολο δεδομένων επικύρωσης. Το σύνολο αυτό παρέχει μια αμερόληπτη αξιολόγηση της προσαρμογής ενός μοντέλου στο σύνολο δεδομένων εκπαίδευσης, ενώ παράλληλα δίνει την δυνατότητα βελτίωσής του, τροποποιώντας τις υπερπαραμέτρους του. Τέλος, το σύνολο δεδομένων δοκιμής είναι ένα σύνολο δεδομένων που χρησιμοποιείται για την τελική, αμερόληπτη αξιολόγηση ενός μοντέλου. Το σύνολο αυτό δεν χρησιμοποιείται σε κανένα άλλο στάδιο ανάπτυξης του μοντέλου (ούτε για εκπαίδευση, ούτε για επικύρωση), παρά μόνο για την τελική ποσοτικοποίηση της επίδοσης του μοντέλου. Στο Σχήμα 3.3 [31] απεικονίζονται τα τρία αυτά σύνολα και παρουσιάζεται η χρησιμότητα του καθενός.



Σχήμα 3.3: Χωρισμός των δεδομένων σε τρία υποσύνολα (sets)

3.3 Βασικές Κατηγορίες αλγορίθμων μηχανικής μάθησης

3.3.1 Ταξινόμηση

Η ταξινόμηση (classification) είναι μια τεχνική εποπτευόμενης μάθησης που χρησιμοποιείται για τον προσδιορισμό της κατηγορίας των νέων παρατηρήσεων με βάση τα δεδομένα εκπαίδευσης. Στην ταξινόμηση, δηλαδή, ο αλγόριθμος μαθαίνει από το σύνολο δεδομένων εκπαίδευσης και στη συνέχεια ταξινομεί τη νέα παρατήρηση σε έναν αριθμό κλάσεων. Χρησιμοποιείται, κυρίως, για την πρόβλεψη της εξόδου για κατηγορικά δεδομένα. Ο αλγόριθμος αυτός που υλοποιεί την ταξινόμηση σε ένα σύνολο δεδομένων είναι γνωστός ως ταξινομητής.

Υπάρχουν τρία είδη ταξινομήσεων:

- 1) η δυαδική ταξινόμηση (binary classification), στην οποία το πρόβλημα ταξινόμησης έχει μόνο δύο πιθανά αποτελέσματα,
- 2) η ταξινόμηση πολλαπλών κλάσεων (multiclass classification), στην οποία το πρόβλημα έχει περισσότερα από δύο αποτελέσματα και
- 3) η ταξινόμηση πολλαπλών ετικετών (multi-label classification) που συνιστά μια γενίκευση της ταξινόμησης πολλαπλών κλάσεων και δίνει τη δυνατότητα αντιστοίχισης δεδομένων εισόδου σε πολλές κλάσεις ταυτόχρονα.

Στα προβλήματα ταξινόμησης, υπάρχουν δύο τύποι μαθητών - αλγορίθμων, οι lazy learners και οι eager learners. Οι lazy learners απλώς αποθηκεύουν το σύνολο δεδομένων εκπαίδευσης και περιμένουν, έως ότου εμφανιστεί το σύνολο δεδομένων δοκιμής. Όταν συμβεί αυτό, η ταξινόμηση πραγματοποιείται με βάση τα πιο σχετικά δεδομένα του αποθηκευμένου συνόλου εκπαίδευσης. Χρειάζεται λίγος χρόνος για την εκπαίδευσή τους αλλά περισσότερος χρόνος για προβλέψεις. Ένα χαρακτηριστικό παράδειγμα αποτελεί ο αλγόριθμος k-NN. Αντίθετα, οι eager learners αναπτύσσουν ένα μοντέλο ταξινόμησης που βασίζεται στο σύνολο δεδομένων εκπαίδευσης πριν λάβουν το σύνολο δεδομένων δοκιμής. Γι' αυτό, χρειάζονται περισσότερο χρόνο στη μάθηση και λιγότερο χρόνο στην πρόβλεψη. Παραδείγματα αποτελούν τα δένδρα απόφασης (decision trees), ο αλγόριθμος Naïve Bayes και τα τεχνητά νευρωνικά δίκτυα (ANN).

Μετρικές Αξιολόγησης Μοντέλου

Υπάρχουν τρεις κύριες μετρικές που χρησιμοποιούνται ευρέως για την αξιολόγηση των μοντέλων ταξινόμησης και αυτές είναι η ακρίβεια (accuracy), η αξιοπιστία (precision) και η ανάκληση (recall).

Στο σημείο αυτό θα πρέπει να ορίσουμε τον πίνακα σύγχυσης (confusion matrix) ενός δυαδικού ταξινομητή. Η μορφή του πίνακα σύγχυσης ενός δυαδικού ταξινομητή παρουσιάζεται στο Σχήμα 3.4 [32]. Κάθε γραμμή του πίνακα δείχνει την κλάση στην οποία όντως ανήκει ένα στοιχείο, ενώ κάθε στήλη την κλάση στην οποία κατηγοριοποιήθηκε από τον ταξινομητή.

		Actual Values	
		Positive	Negative
Predicted Values	Positive	True Positive	False Positive
	Negative	False Negative	True Negative

Σχήμα 3.4: Πίνακας Σύγχυσης

- Ως True Positive (TP) ορίζουμε τον αριθμό των δεδομένων που ανήκουν στην 'θετική' κλάση και προβλέφθηκαν σωστά πως ανήκουν σε αυτήν.
- Ως True Negative (TN) ορίζουμε τον αριθμό των δεδομένων που ανήκουν στην 'αρνητική' κλάση και προβλέφθηκαν σωστά πως ανήκουν σε αυτήν.
- Ως False Positive (FP) ορίζουμε τον αριθμό των δεδομένων που ανήκουν στην 'αρνητική' κλάση, αλλά λανθασμένα έγινε πρόβλεψη πως ανήκουν στην 'θετική'.
- Ως False Negative (FN) ορίζουμε τον αριθμό των δεδομένων που ανήκουν στην 'θετική' κλάση, αλλά λανθασμένα έγινε πρόβλεψη πως ανήκουν στην 'αρνητική'.

Η ακρίβεια (accuracy) ορίζεται ως το ποσοστό των σωστών προβλέψεων για το σύνολο των δεδομένων δοκιμής. Μπορεί να υπολογιστεί εύκολα από την ακόλουθη εξίσωση:

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN} \quad (3.3)$$

Η αξιοπιστία (precision) ορίζεται ως το κλάσμα των δεδομένων που ανήκουν όντως σε μια κλάση προς το σύνολο των δεδομένων που προβλέφτηκε ότι ανήκουν σε αυτή τη συγκεκριμένη κλάση, και δίνεται από την σχέση:

$$Precision = \frac{TP}{TP + FP} = \frac{TN}{TN + FN} \quad (3.4)$$

Η ανάκληση (recall) ορίζεται ως το κλάσμα των δεδομένων που προβλέφτηκε ότι ανήκουν σε μια κλάση ως προς όλα τα παραδείγματα που ανήκουν πραγματικά στην κλάση και δίνεται από τη σχέση:


$$Recall = \frac{TP}{TP + FN} = \frac{TN}{TN + FP} \quad (3.5)$$

Υπάρχει μια ακόμα μετρική που ονομάζεται παράγοντας F1 και αποτελεί έναν συνδυασμό των μετρικών της αξιοπιστίας και της ανάκλησης. Ουσιαστικά, ορίζεται ως η αρμονική μέση ακρίβεια και ανάκληση και λειτουργεί πολύ καλά για μη ισορροπημένα δεδομένα, δηλαδή για περιπτώσεις όπου ο αριθμός των δεδομένων εισόδου που ανήκουν σε μια κλάση είναι πολύ διαφορετικός από τον αριθμό αυτών που ανήκουν στην άλλη. Ο παράγοντας F1 υπολογίζεται από την ακόλουθη εξίσωση:

$$F_1 = 2 * \frac{Precision * Recall}{Precision + Recall} \quad (3.6)$$

Μία τελευταία μετρική για την οποία θα γίνει λόγος είναι η καμπύλη λειτουργικών χαρακτηριστικών δέκτη (receiver operating characteristic curve - ROC). Η καμπύλη είναι, ουσιαστικά, μια γραφική αναπαράσταση που απεικονίζει την αποδοτικότητα ενός διαδικού ταξινομητή, δηλαδή ταξινομητή δύο κλάσεων, καθώς μεταβάλλεται το επίπεδο διάκρισης των κλάσεων (Σχήμα 3.5 [33]). Η καμπύλη δημιουργείται σχεδιάζοντας το true positive rate (TPR), το οποίο είναι ισοδύναμο με την ανάκληση, συναρτήσει του false positive rate (FPR), το οποίο ορίζεται ως:

$$FPR = \frac{FP}{FP + TN} \quad (3.7)$$



Σχήμα 3.5: ROC καμπύλη

Η περιοχή κάτω από την καμπύλη λειτουργικών χαρακτηριστικών δέκτη (area under curve - AUC) χρησιμοποιείται ως ένα αποτελεσματικό κριτήριο για τη αξιολόγηση ταξινομητών. Η τιμή AUC (AUC score) κυμαίνεται από 0 έως 1. Ένα μοντέλο του οποίου οι προβλέψεις είναι 100% λανθασμένες έχει AUC score ίσο με 0, ενώ αυτό του οποίου οι προβλέψεις είναι 100% σωστές έχει AUC score ίσο με 1. Ουσιαστικά, μετρά την ποιότητα των προβλέψεων του μοντέλου ανεξάρτητα από το επίπεδο ταξινόμησης που επιλέγεται.


3.3.2 Ομαδοποίηση

Η ομαδοποίηση (clustering analysis) αποτελεί, όπως αναφέρθηκε, μια μέθοδο μάθησης χωρίς επίβλεψη (unsupervised learning method). Αποσκοπεί στο διαχωρισμό των σημείων δεδομένων σε πολλές συγκεκριμένες ομάδες, έτσι ώστε αυτά τα σημεία δεδομένων που ανήκουν στις ίδιες ομάδες να έχουν παρόμοιες ιδιότητες, ενώ τα σημεία δεδομένων διαφορετικών ομάδων να έχουν, κατά κάποια έννοια, διαφορετικές ιδιότητες. Γενικά, όλες οι μέθοδοι ομαδοποίησης χρησιμοποιούν την ίδια προσέγγιση, δηλαδή πρώτα υπολογίζονται οι ομοιότητες των σημείων δεδομένων, και στη συνέχεια τις χρησιμοποιούν για να γίνει η διάκρισή τους σε ομάδες που μοιράζονται ομοιότητες.

Η πιο ευρέως χρησιμοποιούμενη μέθοδος για ομαδοποίηση είναι η ομαδοποίηση με χρήση του αλγορίθμου k-means. Ο αλγόριθμος αυτός εκχωρεί σημεία δεδομένων σε μια ομάδα, ώστε το άθροισμα της τετραγωνικής απόστασης μεταξύ των σημείων δεδομένων και του κέντρου της ομάδας, δηλαδή ο αριθμητικός μέσος όρος όλων των σημείων δεδομένων που ανήκουν στην ομάδα, να είναι το ελάχιστο δυνατό. Για να υλοποιηθεί ο αλγόριθμος χρειάζεται να καθοριστεί ο αριθμός των ομάδων που αναμένονται. Στη συνέχεια, γίνεται τυχαία αρχικοποίηση των κέντρων των ομάδων, ανάθεση των σημείων δεδομένων σε κάποια από τις ομάδες βάσει της μικρότερης απόστασης από τα κέντρα, επαναυπολογισμός των νέων κέντρων και επανάληψη της ίδιας διαδικασίας έως ότου όλα τα σημεία των δεδομένων παραμείνουν στην ίδια ομάδα. Ένα παράδειγμα των αναλυτικών βημάτων που ακολουθούνται κατά την υλοποίηση του αλγορίθμου k-means παρουσιάζεται στο Σχήμα 3.6 [34]. Συγκεκριμένα, στο παράδειγμα αυτό υλοποιείται ο αλγόριθμος, με σκοπό την τελική δημιουργία δύο ομάδων ($k=2$) και τα αρχικά κέντρα των δύο ομάδων απεικονίζονται με πράσινο και μπλε χρώμα. Κατά τη διαδικασία υλοποίησης των βημάτων, τα σημεία που αναπαρίστανται με πράσινο και μπλε ανήκουν στις ομάδες με κέντρα τα αντίστοιχα χρώματα.

Ένα γνωστό πρόβλημα του αλγορίθμου είναι πως δεδομένης της επαναληπτικής φύσης και της τυχαίας αρχικοποίησης των κέντρων των ομάδων στην αρχή του, διαφορετικές αρχικοποιήσεις μπορεί να οδηγήσουν σε διαφορετικές ομάδες, μιας και ο αλγόριθμος μπορεί να 'κολλήσει' σε ένα τοπικό βέλτιστο και να μην συγκλίνει στο συνολικό βέλτιστο. Γι' αυτό, συνιστάται η εκτέλεση του αλγορίθμου χρησιμοποιώντας διαφορετικές αρχικοποιήσεις κέντρων και η επιλογή των αποτελεσμάτων της εκτέλεσης που απέδωσαν το χαμηλότερο άθροισμα της τετραγωνικής απόστασης.

Η ομαδοποίηση των σημείων δεδομένων μπορεί να γίνει και με βάση την πυκνότητά τους. Η μορφή αυτή ομαδοποίησης αναφέρεται σε μη εποπτευόμενες μεθόδους μάθησης που προσδιορίζουν διακριτές ομάδες/συστάδες στα δεδομένα, με βάση την ιδέα ότι μια συστάδα στο χώρο δεδομένων είναι μια συνεχόμενη περιοχή υψηλής πυκνότητας, χωρισμένη από άλλες τέτοιες συστάδες με συνεχόμενες περιοχές χαμηλής πυκνότητας. Ένας βασικός αλγόριθμος για ομαδοποίηση με βάση την πυκνότητα αποτελεί η χωρική ομαδοποίηση εφαρμογών με θόρυβο βάσει πυκνότητας (DBSCAN - Density-Based




Σχήμα 3.6: k-means Clustering


Spatial Clustering of Applications with Noise). Ο αλγόριθμος μπορεί να ανακαλύψει συστάδες διαφορετικών σχημάτων και μεγεθών από μια μεγάλη ποσότητα δεδομένων, τα οποία περιέχουν θόρυβο και ακραίες τιμές.

Κατά την εφαρμογή του αλγορίθμου γίνεται αξιοποίηση δύο παραμέτρων, της παραμέτρου minPts που καθορίζει τον ελάχιστο αριθμό σημείων (ένα κατώφλι) που συγκεντρώνονται για μια περιοχή που πρέπει να θεωρείται πυκνή, και την παράμετρο ϵ (epsilon) που αποτελεί το μέτρο απόστασης που θα χρησιμοποιηθεί για τον εντοπισμό των σημείων στη γειτονιά οποιουδήποτε σημείου. Η αλγοριθμική διαδικασία που ακολουθείται είναι η εξής: ο αλγόριθμος προχωρά συλλέγοντας αυθαίρετα ένα σημείο στο σύνολο δεδομένων (μέχρι να γίνει επίσκεψη σε όλα τα σημεία). Εάν υπάρχουν σημεία σε αριθμό τουλάχιστον ίσα με την παράμετρο minPoint σε ακτίνα ίση με ϵ από το εξεταζόμενο σημείο, τότε θεωρείται ότι όλα αυτά τα σημεία είναι μέρος της ίδιας ομάδας. Στη συνέχεια, οι ομάδες επεκτείνονται επαναλαμβάνοντας αναδρομικά τον υπολογισμό γειτονιάς για κάθε διπλανό σημείο. Ένα παράδειγμα υλοποίησης του αλγορίθμου DBSCAN απεικονίζεται στο Σχήμα 3.7 [35].

Πολύ σημαντικό χαρακτηριστικό του αλγορίθμου είναι πως δεν απαιτεί προγενέστερη γνώση του αριθμού των ομάδων που πρέπει να δημιουργηθούν. Τέλος, είναι γνωστό πως ο DBSCAN παρέχει πιο λογικά αποτελέσματα από τον k-means όταν τα σημεία δεδομένων έχουν διαφορετικές κατανομές. Προκειμένου να γίνουν πιο κατανοητά τα βήματα που ακολουθούνται για την υλοποίηση των δύο αλγορίθμων, παρουσιάζεται μία αντιπαράθεση των ομάδων που δημιουργούνται με τη χρήση τους στα δύο ίδια προβλήματα του Σχήματος 3.8 [36].



Σχήμα 3.7: DBSCAN



Σχήμα 3.8: Σύγκριση των αλγορίθμων k-means και DBSCAN

3.4 Βαθιά Μηχανική Μάθηση

Η βαθιά μάθηση μπορεί να θεωρηθεί ως υποσύνολο της μηχανικής μάθησης και χαρακτηριστικό της αποτελεί η ικανότητα εξαγωγής πληροφοριών από ένα σύνολο δεδομένων χωρίς προηγούμενη γνώση, αλλά και υπολογισμού πολύπλοκων σχέσεων από το σύνολο αυτό. Αν και η μηχανική μάθηση χρησιμοποιεί απλούστερες έννοιες, η βαθιά μάθηση λειτουργεί με σύνθετα νευρωνικά δίκτυα, τα οποία σχεδιάζονται για να μιμούνται τον τρόπο με τον οποίο οι άνθρωποι σκέφτονται και μαθαίνουν.

3.4.1 Νευρωνικά δίκτυα

Το όνομα και η δομή των νευρωνικών δικτύων, ή αλλιώς Τεχνητών Νευρωνικών Δικτύων (Artificial Neural Networks) είναι εμπνευσμένα από τον ανθρώπινο εγκέφαλο, καθώς μιμούνται τον τρόπο που

οι βιολογικοί νευρώνες δίνουν σήμα ο ένας στον άλλο.


Ο τεχνητός νευρώνας (artificial neuron) είναι στην πραγματικότητα μια μαθηματική μοντελοποίηση του ανθρώπινου νευρώνα, ο οποίος δέχεται μια σειρά εισόδων, τις συνδυάζει και παράγει μια έξοδο. Το σύνολο των εισόδων x_i που δέχεται ο νευρώνας πολλαπλασιάζονται με τα αντίστοιχα βάρη w_i και αθροίζονται στην έξοδο. Τα βάρη w_i είναι ουσιαστικά οι παράμετροι οι οποίες επιθυμείται να υπολογιστούν από το δίκτυο μέσω της διαδικασίας μάθησης. Με άλλα λόγια, σκοπός του κάθε νευρώνα είναι να μπορεί να προσεγγίσει την έξοδό του ρυθμίζοντας τα βάρη w_i προκειμένου αυτή να προκύπτει από τις αντίστοιχες εισόδους του. Η εξίσωση λειτουργίας του νευρώνα είναι η ακόλουθη:

$$y = \sum_{n=1}^N w_n x_n + w_b \quad (3.8)$$

όπου η σταθερά w_b αποτελεί την πόλωση του νευρώνα (bias).

Ακόμη, αν επιθυμείται η τιμή της εξόδου να πληρεί κάποιες προϋποθέσεις, όπως να παίρνει τιμή μεταξύ κάποιων προκαθορισμένων ορίων, τότε διέρχεται από μια συνάρτηση ενεργοποίησης (activation function). Ουσιαστικά, οι συναρτήσεις ενεργοποίησης αποτελούν μαθηματικές συναρτήσεις που δέχονται ως είσοδο το ζυγισμένο άθροισμα των βαρών του νευρώνα και παράγουν ως αποτέλεσμα μια αριθμητική τιμή. Κρίνεται σκόπιμο οι συναρτήσεις ενεργοποίησης να είναι μη γραμμικές, ώστε να είναι δυνατό να εκπαιδευτεί ο νευρώνας σε μη γραμμικά σύνολα δεδομένων.

Η δομή ενός τεχνητού νευρώνα απεικονίζεται στο Σχήμα 3.9 [37].



Σχήμα 3.9: Απεικόνιση τεχνητού νευρώνα


Τα νευρωνικά δίκτυα αποτελούνται από στρώματα κόμβων, δηλαδή νευρώνων (node layers), τα οποία περιέχουν ένα στρώμα εισόδου (input layer), ένα ή περισσότερα κρυφά στρώματα (hidden layers) και ένα στρώμα εξόδου (output layer). Οι νευρώνες των κρυφών στρωμάτων, δηλαδή οι λεγόμενοι κρυφοί νευρώνες, προσπαθούν να μάθουν τα χαρακτηριστικά της εισόδου. Για να το πετύχουν αυτό, μετασχηματίζουν τα δεδομένα εισόδου σε ένα νέο χώρο, ο οποίος ονομάζεται χώρος χαρακτηριστικών (feature). Κάθε επίπεδο είναι συνδεδεμένο με το αμέσως προηγούμενο και το αμέσως επόμενο του, και κάθε νευρώνας ενός επιπέδου συνδέεται με όλους τους νευρώνες του προηγούμενου και του επόμενου επιπέδου, αλλά όχι με τους νευρώνες που ανήκουν στο ίδιο επίπεδο

με αυτόν. Ουσιαστικά, κάθε νευρώνας έχει ένα σχετικό βάρος και ένα κατώφλι. Εάν η έξοδος οποιουδήποτε μεμονωμένου νευρώνα είναι μεγαλύτερη από την καθορισμένη τιμή κατωφλίου, αυτός ο νευρώνας ενεργοποιείται, στέλνοντας δεδομένα στο επόμενο επίπεδο του δικτύου. Σε αντίθετη περίπτωση δεν διαβιβάζονται δεδομένα στο επόμενο επίπεδο του δικτύου. Άξιο επισημάνσης είναι πως ο αριθμός των νευρώνων σε κάθε επίπεδο μπορεί να διαφέρει. Συνήθως, δίκτυα με περισσότερα κρυφά επίπεδα, τα λεγόμενα βαθύτερα δίκτυα, λειτουργούν με καλύτερη απόδοση.

Απαραίτητη στη δημιουργία νευρωνικών δικτύων αποτελεί η χρήση συναρτήσεων κόστους (loss functions). Οι συναρτήσεις αυτές χρησιμοποιούνται για να 'καθοδηγήσουν' την εκπαίδευση του δικτύου, συγκρίνοντας την έξοδο του δικτύου για κάποια δεδομένη είσοδο με την σωστή έξοδο που θα έπρεπε να δώσει το δίκτυο για αυτήν την είσοδο (στόχος). Η διαφορά μεταξύ της επιθυμητής εξόδου και της εξόδου του δικτύου χρησιμοποιείται, στην συνέχεια, από έναν βελτιστοποιητή για να προσαρμόσει τα βάρη του δικτύου. Όπως έχει, ήδη, αναφερθεί, στην επιβλεπόμενη μάθηση ο στόχος είναι κάποια ετικέτα που περιγράφει την είσοδο ενώ, στην περίπτωση της μη-επιβλεπόμενης μάθησης, δεν δίνεται στόχος στο δίκτυο, καθώς αναμένεται να τον εκτιμήσει το δίκτυο από τα ίδια τα δεδομένα.

Οι βελτιστοποιητές (optimizers) είναι αλγόριθμοι που έχουν ως σκοπό να ελαχιστοποιήσουν τη συνάρτηση κόστους, ενημερώνοντας και προσαρμόζοντας τα βάρη του δικτύου. Ευρέως χρησιμοποιούμενοι βελτιστοποιητές είναι ο αλγόριθμος της Στοχαστικής Κατάβασης Κλίσης και ο αλγόριθμος Adam.

Στο Σχήμα 3.10 παρουσιάζεται ένα νευρωνικό δίκτυο [38].




Σχήμα 3.10: Δομή Νευρωνικού Δικτύου

3.4.2 Συνελικτικά Νευρωνικά Δίκτυα

Τα συνελικτικά νευρωνικά δίκτυα (Convolutional Neural Networks) πήραν το όνομά τους από τη μαθηματική γραμμική λειτουργία μεταξύ πινάκων που ονομάζεται συνέλιξη. Στην πραγματικότητα, περιλαμβάνουν συνελικτικά επίπεδα (convolutional layers) τα οποία λαμβάνουν ως είσοδο κάποιο

διάνυσμα και εκτελούν τη πράξη της συνέλιξης μεταξύ της εισόδου και του φίλτρου τους. Περιλαμβάνουν και άλλα πολλαπλά επίπεδα, μεταξύ των οποίων βρίσκονται τα επίπεδα υποδειγματοληψίας (pooling layers) και τα πλήρως συνδεδεμένα επίπεδα (fully connected layer) [39]. Μια τυπική μορφή ενός συνελικτικού νευρωνικού δικτύου που δέχεται ως είσοδο μια εικόνα παρουσιάζεται στο Σχήμα 3.11 [40].



Σχήμα 3.11: Συνελικτικό Νευρωνικό Δίκτυο

Τα συνελικτικά δίκτυα χρησιμοποιούνται κυρίως σε προβλήματα που σχετίζονται με χωρική πληροφορία και το μεγαλύτερο πλεονέκτημά τους συγκριτικά με τα απλά νευρωνικά δίκτυα είναι η μείωση του αριθμού των παραμέτρων που απαιτούνται να υπολογιστούν μέσω της διαδικασίας εκπαίδευσης. Έτσι, τα δίκτυα αυτά έδωσαν τη δυνατότητα καλύτερης προσέγγισης πολύ μεγαλύτερων μοντέλων προκειμένου να επιλυθούν πολύπλοκες διεργασίες, οι οποίες δεν ήταν δυνατές με χρήση των κλασικών ANNs.

Έχουν εξαιρετική απόδοση σε εφαρμογές που ασχολούνται με δεδομένα εικόνων, μιας και η αρχιτεκτονική τους είναι ιδανική για την εύρεση μοτίβων και βασικών χαρακτηριστικών σε χωρικά δεδομένα, αλλά και σε εφαρμογές που σχετίζονται με επεξεργασία φυσικής γλώσσας (NLP - Natural Language Processing). Επιπλέον, χρησιμοποιούνται αποτελεσματικά και για την επεξεργασία άλλων δεδομένων, όπως για παράδειγμα οι χρονοσειρές, ο ήχος, καθώς και άλλα είδη σημάτων. Μια δεδομένη συνθήκη που πρέπει να πληρούν τα προβλήματα που επιλύονται με χρήση συνελικτικών νευρωνικών δικτύων είναι πως είναι αναγκαίο να μην έχουν χαρακτηριστικά που έχουν εξάρτηση από το χώρο. Χαρακτηριστικό παράδειγμα αποτελεί πως σε μια εφαρμογή που έχει ως σκοπό την ανίχνευση προσώπου δεν θα δοθεί έμφαση στη θέση που βρίσκεται το πρόσωπο μέσα στην κάθε εικόνα, αλλά στην ανίχνευσή του στην δεδομένη εικόνα.

Όσον αφορά περισσότερες λεπτομέρειες για την αρχιτεκτονική, ένα τέτοιο δίκτυο αποτελείται από ένα ή περισσότερα επίπεδα συνέλιξης τα οποία ακολουθούνται από επίπεδα υποδειγματοληψίας. Τα επίπεδα αυτά μειώνουν τις διαστάσεις των χαρτών που περιέχουν τα χαρακτηριστικά (features) που προκύπτουν από τα συνελικτικά στρώματα και τις περισσότερες φορές, στο τέλος του δικτύου εντοπίζονται πλήρη συνδεδεμένα επίπεδα. Στα πρώτα επίπεδα το μοντέλο μαθαίνει να αναγνωρίζει κάποιες βασικές δομές των εισόδων, ενώ στα βαθύτερα αυξάνεται η πολυπλοκότητα και εξάγονται συμπεράσματα για τα πιο σύνθετα χαρακτηριστικά.

3.4.2.1 Συνελικτικά Επίπεδα (Convolutional Layers)

Το σημαντικότερο χαρακτηριστικό τους αποτελεί το συνελικτικό φίλτρο (convolutional kernel), το οποίο, όπως έχει ήδη αναφερθεί, πραγματοποιεί την πράξη της συνέλιξης στα δεδομένα εισόδου. Η μαθηματική έκφραση της πράξης της συνέλιξης είναι η ακόλουθη:

$$y[k] = (x * h)[k][n] = \sum_{n=j} h[i][j]x[k-i][n-j] \quad (3.9)$$

Το μέγεθος του φίλτρου (kernel size) αποτελεί ένα πολύ μικρό κλάσμα των δεδομένων εισόδου και υλοποιεί τμηματικά την πράξη της συνέλιξης κατά μήκος του συνολικού εύρους των δεδομένων.

Το άλμα βάσει του οποίου γίνεται μετάβαση του φίλτρου από το ένα τμήμα των δεδομένων εισόδου στο διπλανό του ρυθμίζεται από το βήμα του φίλτρου (kernel stride). Το βήμα αυτό καθορίζει πόσες χωρικές μονάδες θα μετακινείται το φίλτρο του συνελικτικού επιπέδου πάνω στα δεδομένα εισόδου οριζόντια και κάθετα. Όταν το βήμα αυτό έχει μεγάλη τιμή μειώνεται ο συνολικός χρόνος της πράξης της συνέλιξης. Γι' αυτό, στην περίπτωση ύπαρξης δεδομένων με μεγάλο όγκο και διαστάσεις, το βήμα προτιμάται να έχει τιμή μεγαλύτερη της μονάδας.

Η υπερπαραμέτρος zero-padding χρησιμοποιείται για να προσθέσει μηδενικά στο περίγραμμα της εισόδου. Αυτή η διαδικασία μπορεί να βοηθήσει στην περίπτωση ανάγκης διατήρησης των διαστάσεων της εισόδου και εφαρμογής δεδομένου μεγέθους φίλτρου για τη σάρωση των χαρακτηριστικών της.

Τελικό αποτέλεσμα της συνελικτικής διαδικασίας των δεδομένων εισόδου με το φίλτρο αποτελεί ο χάρτης χαρακτηριστικών (feature mapping). Ο χάρτης αυτός περιλαμβάνει συσχετίσεις χωρικής πολυπλοκότητας, η οποία αποικοδομείται από τα συνελικτικά στρώματα στα κανάλια εξόδου. Η ίδια διαδικασία επαναλαμβάνεται με διαφορετικά φίλτρα ώστε να παραχθεί ένα σύνολο χαρτών που αναπαριστούν διαφορετικά χαρακτηριστικά της εισόδου.

Συνήθως η είσοδος ενός συνελικτικού επιπέδου είναι τρισδιάστατη. Το μέγεθος της εξόδου του επιπέδου ελέγχεται από τις τρεις υπερπαραμέτρους που αναφέρθηκαν, το μέγεθος του φίλτρου, το άλμα του φίλτρου και το zero padding. Πιο συγκεκριμένα, το μέγεθος της εξόδου ενός συνελικτικού επιπέδου δίνεται από την ακόλουθη σχέση:

$$O = \frac{I - K + 2P}{S} + 1 \quad (3.10)$$

όπου

O το μέγεθος της εξόδου (output size),

I το μέγεθος της εισόδου (input size),

K το μέγεθος του φίλτρου (kernel size),

S το άλμα του φίλτρου (kernel stride) και

P το padding.

3.4.2.2 Συναρτήσεις ενεργοποίησης (Activation functions)

Οι συναρτήσεις ενεργοποίησης έχουν ήδη αναφερθεί στα Τεχνητά Νευρωνικά Δίκτυα. Υπενθυμίζεται ότι στην περίπτωση που η έξοδος ενός ενός νευρώνα επιθυμείται να βρίσκεται μεταξύ συγκεκριμένων ορίων εφαρμόζεται η συνάρτηση ενεργοποίησης, η οποία ουσιαστικά αυτό που κάνει είναι να πραγματοποιεί έναν μη γραμμικό μετασχηματισμό στην τιμή της εξόδου.

Η επιλογή συνάρτησης ενεργοποίησης είναι πολύ σημαντική για την απόδοση του δικτύου, αφού αυτή καθορίζει πόσο σημαντικό ρόλο έχει ο κάθε νευρώνας στο δίκτυο. Έτσι, εξαιτίας της χρήσης μιας επιλεγμένης συνάρτησης ενεργοποίησης, ενδέχεται τα βάρη προς κάποιους νευρώνες να έχουν μικρές τιμές, δηλαδή η συνεισφορά τους στο δίκτυο να είναι μηδαμινή, ενώ τα βάρη προς άλλους νευρώνες να έχουν μεγάλες τιμές, δηλαδή η συνεισφορά τους στο δίκτυο να είναι μεγάλη.

Ευρεία εφαρμογή στα νευρωνικά δίκτυα βρίσκουν η συνάρτηση διάδοσης ReLU - Rectified Linear Activation Unit, οι συναρτήσεις υπερβολικής εφαπτομένης και οι σιγμοειδείς.

Η ReLU ορίζεται ως :

$$f(x) = \max(0, x) \quad (3.11)$$


Η συνάρτηση υπερβολικής εφαπτομένης δίνεται από την εξίσωση:

$$\tanh(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}} \quad (3.12)$$

Τέλος, η σιγμοειδής συνάρτηση, δίνεται από την εξίσωση:

$$\sigma(x) = \frac{1}{1 + e^{-x}} \quad (3.13)$$

Οι γραφικές τους παραστάσεις απεικονίζονται στο Σχήμα 3.12 [41].




Σχήμα 3.12: Συναρτήσεις Ενεργοποίησης

3.4.2.3 Επίπεδα Υποδειματοληψίας (Pooling Layers)

Ένα επίπεδο υποδειματοληψίας δέχεται ως είσοδο τον χάρτη χαρακτηριστικών που προέκυψε από το αμέσως προηγούμενο συνελικτικό επίπεδο και έχει ως σκοπό την μείωση των διαστάσεων του χωρίς, όμως, να υπάρχει σημαντική μείωση της χρήσιμης πληροφορίας του. Έτσι, ο χρόνος επεξεργασίας βελτιώνεται, ενώ παράλληλα δεν χάνεται η χρήσιμη πληροφορία του χάρτη.

Ουσιαστικά κατά τη διαδικασία υποδειματοληψίας, ένα φίλτρο, που αντιστοιχεί πρακτικά σε μια μαθηματική συνάρτηση, εφαρμόζεται σε όλο τον χάρτη υπολογίζοντας της υποδειματοληπτημένη εκδοχή του. Δύο είναι οι βασικές συναρτήσεις που χρησιμοποιούνται σ' αυτή τη διαδικασία και αυτές είναι η max pooling και η average pooling. Η max pooling επιλέγει το μέγιστο στοιχείο του χάρτη στο οποίο εφαρμόζεται το φίλτρο, ενώ η average pooling επιλέγει το μέσο όρο των στοιχείων του

χάρτη αντίστοιχα. Ένα παράδειγμα max pooling και average pooling παρουσιάζεται στο Σχήμα 3.13 [42].



Σχήμα 3.13: Παράδειγμα Max και Average Pooling

Το μέγεθος της εξόδου του επιπέδου ελέγχεται από το μέγεθος του φίλτρου (pool size) και το άλμα του φίλτρου pool stride και δίνεται από την ακόλουθη σχέση:

$$O = \frac{I - P_s}{S} + 1 \quad (3.14)$$

όπου

O το μέγεθος της εξόδου του επιπέδου(output size),
I το μέγεθος της εισόδου του επιπέδου(input size),
 P_s το μέγεθος του φίλτρου (pool size) και
S το άλμα του φίλτρου (pool stride).


3.4.2.4 Πλήρως Συνδεδεμένα Επίπεδα (Fully-connected layers)

Στα πλήρως συνδεδεμένα επίπεδα, κάθε κόμβος(νευρώνας) του προηγούμενου επιπέδου συνδέεται απευθείας με κάθε κόμβο του επόμενου. Είναι συχνό φαινόμενο να τοποθετούνται στο τέλος του συνελικτικού νευρωνικού δικτύου για να επιτευχθεί ταξινόμηση της εισόδου σε κάποια από τις πιθανές κλάσεις, χρησιμοποιώντας τους χάρτες χαρακτηριστικών (feature maps) που προέκυψαν από τα προηγούμενα επίπεδα. Το τελευταίο τέτοιο επίπεδο περιέχει αριθμό κόμβων ίσο με τις αρχικές κλάσεις που είχε το πρόβλημα ταξινόμησης και καθορίζει το μοντέλο απόφασης του δικτύου. Με άλλα λόγια, το μοντέλο απόφασης του δικτύου καθορίζεται στα πλήρως συνδεδεμένα επίπεδα. Ένα παράδειγμα πλήρως συνδεδεμένου επιπέδου απεικονίζεται στο Σχήμα 3.14 [43].

3.4.2.5 Άλλα Επίπεδα

Επίπεδο Αποκοπής Νευρώνων (Dropout Layer)

Η τεχνική αυτή χρησιμοποιείται για την αποφυγή υπερεκπαίδευσης στα δεδομένα εκπαίδευσης, η




Σχήμα 3.14: Παράδειγμα Fully connected layer που υλοποιεί ταξινόμηση σε 5 κλάσεις

οποία αποτελεί μια ανεπιθύμητη κατάσταση. Η υπερεκπαίδευση συμβαίνει όταν ένα συγκεκριμένο μοντέλο μαθαίνει να λειτουργεί καλά στα δεδομένα εκπαίδευσης αλλά η απόδοσή του μειώνεται σημαντικά όταν χρησιμοποιείται σε νέα δεδομένα που δεν έχει ξαναμελετήσει (unseen data). Για να αντιμετωπιστεί αυτό το πρόβλημα χρησιμοποιούνται κάποια επίπεδα αποκοπής, στα οποία αποκόπτονται προσωρινά, κατά τη διάρκεια της εκπαίδευσης, κάποιοι νευρώνες μαζί με τις συνδέσεις τους, οδηγώντας στη μείωση του μεγέθους του μοντέλου. Κάθε νευρώνας έχει μια συγκεκριμένη πιθανότητα αφαίρεσης από το δίκτυο εκπαίδευσης. Η πιθανότητα αυτή ονομάζεται ρυθμός εγκατάλειψης (dropout rate) και λαμβάνει τυπικές τιμές 0.2 με 0.5. Η τεχνική αυτή απεικονίζεται στο Σχήμα 3.15. Αριστερά παρουσιάζεται ένα πλήρως συνδεδεμένο νευρωνικό δίκτυο, ενώ αριστερά το ίδιο δίκτυο με εφαρμογή dropout [44].

Κανονικοποίηση Παρτίδας (Batch Normalization)

Η βασική ιδέα της τεχνικής της Κανονικοποίησης Παρτίδας έγκειται στην κανονικοποίηση των δεδομένων εισόδου σε κάθε επίπεδο του δικτύου. Πιο συγκεκριμένα, όπως υποδηλώνει και το όνομά της, η τεχνική κανονικοποιεί το αποτέλεσμα της συνάρτησης ενεργοποίησης του προηγούμενου επιπέδου, πριν αυτό μεταβεί στο επόμενο επίπεδο. Συνήθως η κανονικοποίηση γίνεται έτσι ώστε η μέση τιμή της συνάρτησης ενεργοποίησης να προσεγγίζει την τιμή 0, ενώ σπανιότερα την τιμή 1.

Είναι γεγονός πως η εκπαίδευση ενός νευρωνικού δικτύου είναι πολύπλοκη, μιας και οι τιμές των δεδομένων εισόδου κάθε επιπέδου επηρεάζονται από τις παραμέτρους κάθε προηγούμενου και έτσι, μικρές μεταβολές στις τιμές των παραμέτρων αυξάνονται όσο το δίκτυο γίνεται βαθύτερο. Προκειμένου τα δεδομένα εισόδου των επιπέδων να ακολουθούν μία κοινή κατανομή, και συγκεκριμένα την




Σχήμα 3.15: Επίπεδο Αποκοπής Νευρώνων

κανονική, γίνεται χρήση της εν λόγω τακτικής. Αξίζει να αναφερθεί ότι η χρήση επιπέδων Κανονικοποίησης Παρτίδας βελτιώνει σημαντικά την ταχύτητα εκπαίδευσης, χωρίς να μειώνει ποιοτικά το αποτέλεσμα της εξόδου.

Κεφάλαιο 4

Πειραματική Διαδικασία

Τα δεδομένα που χρησιμοποιήθηκαν για την εκπόνηση της παρούσας διπλωματικής αποτελούν μέρος ενός ανοιχτού συνόλου δεδομένων (dataset) [45] που δημοσιεύτηκε το Δεκέμβριο του 2021. Το dataset δημιουργήθηκε μετά από υλοποίηση ηλεκτροεγκεφαλογράφηματος (scalp και ear-EEG), και ταυτόχρονη χρησιμοποίηση αισθητήρων κίνησης (locomotion sensors) από 24 συμμετέχοντες που κινούνταν σε ένα διάδρομο (κλίσης 0°) με τέσσερις διαφορετικές ταχύτητες, ενώ εκτελούσαν δύο εργασίες διεπαφής εγκεφάλου-υπολογιστή (BCI - Brain-Computer Interface). Πιο συγκεκριμένα, τα δεδομένα συλλέχτηκαν από 32 κανάλια scalp EEG, 14 κανάλια ear EEG, 4 κανάλια ηλεκτροοφθαλμογραφίας (EOG) και 9 κανάλια αδρανειακών μονάδων μέτρησης (IMU), τοποθετημένα στο μέτωπο, τον αριστερό αστράγαλο και τον δεξιό αστράγαλο. Η πειραματική διαδικασία απεικονίζεται στο Σχήμα 4.1.




Σχήμα 4.1: Experimental design

Οι ακριβείς συνθήκες κίνησης κατά την διαδικασία καταγραφής ήταν η ακινησία (κίνηση με ταχύτητα ίση 0 m/s), το αργό περπάτημα (κίνηση με ταχύτητα ίση 0.8 m/s), το γρήγορο περπάτημα (κίνηση με ταχύτητα ίση 1.6 m/s) και το ελαφρύ τρέξιμο (κίνηση με ταχύτητα ίση 2 m/s). Για κάθε ταχύτητα, καταγράφηκαν δύο διαφορετικά παραδείγματα BCI και συγκεκριμένα, δυναμικό που σχετίζεται με κάποιο γεγονός (ERP), και οπτικά προκλητό δυναμικό σταθερής κατάστασης (SSVEP). Επισημαίνεται ότι οι συμμετέχοντες παρακολούθηθηκαν και έλαβαν οδηγίες να ελαχιστοποιήσουν άλλες κινήσεις, όπως του λαιμού ή του βραχίονα, ώστε να αποφευχθεί η δημιουργία artifacts που μπορεί να προκύψουν από άλλες κινήσεις εκτός από το περπάτημα.

Η μελέτη εγκρίθηκε από το Ιδρυματικό Συμβούλιο Αναθεώρησης του Πανεπιστημίου της Κορέας (Institutional Review Board of Korea University) και όλοι οι συμμετέχοντες παρείχαν γραπτή ενημερωμένη συγκατάθεση πριν από την υλοποίηση των πειραμάτων. Όλα τα πειράματα διεξήχθησαν σύμφωνα με την Διακήρυξη (Declaration) του Ελσίνκι.

4.1 Δεδομένα

Τα δεδομένα που αξιοποιήθηκαν από το συνολικό dataset, στα πλαίσια εκπόνησης της διπλωματικής αυτής, είναι τα σήματα, δηλαδή οι χρονοσειρές, της εγκεφαλικής δραστηριότητας που εντοπίστηκε γύρω από την περιοχή του αυτιού (ear-EEG) κατά την πρόκληση οπτικών δυναμικών ERP. Το ear-EEG υλοποιήθηκε με χρήση ηλεκτροδίων cEEGrid που τοποθετήθηκαν γύρω από κάθε αυτί του κάθε συμμετέχοντος, με οκτώ κανάλια στα αριστερά (L1, L2, L4, L5, L6, L7, L9, L10), έξι κανάλια στα δεξιά (R1, R2, R4, R5, R7, R8) και τα κανάλια γείωσης (Gnd) και αναφοράς (Ref) στα δεξιά στο κέντρο, όπως φαίνεται στο Σχήμα 4.2. Τα δεδομένα καταγράφηκαν με ρυθμό δειγματοληψίας 500 Hz και ανάλυση 24 bit. Όλες οι σύνθετες αντιστάσεις του ear-EEG διατηρήθηκαν κάτω από 50 kΩ και τα περισσότερα κανάλια μειώθηκαν σε κάτω από 20 kΩ.




Σχήμα 4.2: Θέσεις ηλεκτροδίων ear-EEG

4.2 Συμμετέχοντες και ERP tasks

Οι συμμετέχοντες που πήραν μέρος στα πειράματα απαρτίζονται από 24 υγιή άτομα (14 άνδρες και 10 γυναίκες), ηλικίας 24.5 ± 2.9 ετών, χωρίς κανένα ιστορικό νευρολογικής παθολογίας. Όλοι οι

συμμετέχοντες πήραν μέρος στην υλοποίηση των tasks ERP για τα sessions ακινησίας (0 m/s), αργού περπατήματος (0.8 m/s) και γρήγορου περπατήματος (1.6 m/s), αλλά μόνο 17 πραγματοποίησαν το session κίνησης με ελαφρύ τρέξιμο (2 m/s).

Κατά τη διάρκεια των ERP tasks, οι χαρακτήρες στόχου - target ('OOO') και μη-στόχου - non target ('XXX') παρουσιάζονταν στην οθόνη ως οπτικά ερεθίσματα. Όλοι οι χαρακτήρες εμφανίζονταν με μαύρο φόντο στο κέντρο της οθόνης. Το ποσοστό της εμφάνισης χαρακτήρων στόχων ήταν 0.2 και ο συνολικός αριθμός δοκιμών για κάθε συμμετέχοντα ήταν 300 (300 trials). Σε κάθε δοκιμή, καθένα από τα ερεθίσματα παρουσιάστηκε για 0.5 sec και έπειτα εμφανίστηκε το σύμβολο ('+') για να γίνει ένα διάλειμμα για χρονικό διάστημα ίσο με 0.5 - 1.5 sec, όπως φαίνεται στο Σχήμα 4.3. Η συνολική διάρκεια ενός session κίνησης για τα ERP-tasks είναι ίση με 7 - 8 λεπτά.




Σχήμα 4.3: ERP tasks

4.3 Ear-EEG Σήματα

Έγινε μια πρώτη προεπεξεργασία των δεδομένων από τους δημιουργούς του dataset. Αρχικά, τα σήματα φιλτραρίστηκαν με χρήση Butterworth φίλτρου υψηλής διέλευσης (high pass filter) 5ης τάξης με συχνότητα αποκοπής ίση με 0.5 Hz, έτσι ώστε να γίνει αφαίρεση των DC components. Στη συνέχεια, εφαρμόστηκε η τεχνική αφαίρεσης θορύβου γραμμής (line noise removal) ώστε να επιτευχθεί αφαίρεση των artifacts που περιείχαν θόρυβο για εκτεταμένες χρονικές περιόδους. Πιο συγκεκριμένα, η μέθοδος αφαίρεσε τα 'κακά' κανάλια που έφεραν μη φυσιολογικά σήματα με τυπικές αποκλίσεις πάνω από ένα όριο z-score, χρησιμοποιώντας την συνάρτηση flt clean channels του BCILAB στο Matlab με κατώφλι ίσο με 4 και χρονικό μήκος παραθύρου ίσο με 5 sec. Για τα θεωρούμενα 'κακά' κανάλια έγινε χρήση της τεχνικής παρεμβολής (interpolation), και συγκεκριμένα της μεθόδου super-fast spherical method, έτσι ώστε να μη χαθεί η πληροφορία που εμπεριέχεται σε αυτά. Πρακτικά, έγινε αφαίρεση και παρεμβολή 1.35 ± 1.18 καναλιών ear-EEG για το σύνολο των συμμετεχόντων σε όλα τα sessions κίνησης. Ακόμη, χρησιμοποιήθηκε ένα κοινό κανάλι αναφοράς για τα σήματα ear-EEG και πραγματοποιήθηκε υποδειγματοληψία τους με συχνότητα δειγματοληψίας ίση με 100 Hz. Τέλος, τα συνεχή σήματα χωρίστηκαν σε επιμέρους σήματα ίσα με τον αριθμό των trials για κάθε session κίνησης. Ουσιαστικά, έγινε αποκοπή των σημάτων που προέκυψαν κατά υλοποίηση των ERP tasks, και συγκεκριμένα ως ένα σήμα θεωρήθηκε αυτό που προέκυψε -200 msec πριν την εμφάνιση του στόχου / μη-στόχου και 800 msec μετά απ' αυτό, μιας και αυτό θεωρείται το ERP signal. Τελικά, το μέγεθος κάθε σήματος στο πεδίο του χρόνου είναι ίσο με 100 δείγματα (samples). Στο Σχήμα 4.4 απεικονίζεται, ενδεικτικά, η μορφή ενός σήματος του καναλιού R8 για κάποιο trial για κάθε session κίνησης ενός συμμετέχοντα στο πεδίο του χρόνου. Σημειώνεται πως

για το καθένα έχει πραγματοποιηθεί κανονικοποίηση, με αφαίρεση της μέσης τιμής του και διαίρεση με την τυπική του απόκλιση.



Σχήμα 4.4: ear-EEG signal για κάθε session κίνησης


Όπως έχει αναφερθεί, επειδή τα σήματα ERP έχουν πολύ μικρό πλάτος, πραγματοποιείται signal averaging επαναλαμβανόμενων trials όταν επιθυμείται να εξαχθεί σαφές συμπέρασμα για τη μορφή του σήματος στο πεδίο του χρόνου. Έτσι, για απεικονιστικούς λόγους, επιλέχθηκε να εφαρμοστεί signal averaging για όλα τα σήματα του συνόλου των συμμετεχόντων του καναλιού L10, ενώ παράλληλα έγινε διάκριση των σημάτων σε αυτά που παρατηρούνται όταν εμφανίζονται οι χαρακτήρες στόχου ή μη-στόχου, ώστε να παρουσιαστεί η μορφή τους. Με άλλα λόγια, έγινε και διάκριση των σημάτων σε δύο κατηγορίες, target(στόχου) και non-target (μη-στόχου).

Παρατηρώντας τη μορφή των signal averaged σημάτων στο πεδίο του χρόνου για τα διάφορα κανάλια του ear-EEG εντοπίζεται για την περίπτωση των target signals με την αύξηση της ταχύτητας, μειώνεται το πλάτος του P300 component του μέσου ERP σήματος, όπως άλλωστε επιβεβαιώνεται και στο paper [45].

Το component P300 εμφανίζεται σαν μια απότομη αύξηση της εγκεφαλικής δραστηριότητας (θετικό δυναμικό) περίπου 300 msec μετά από ένα ερέθισμα, ενώ η καθυστέρηση του εξαρτάται από τη διάρκεια της αξιολόγησης και επεξεργασίας του ερεθίσματος στόχου [46], [47]. Έχει θεωρηθεί ως ένας πιθανός δείκτης γνωστικής δυσλειτουργίας, ενώ έχει βρεθεί ότι το πλάτος του μειώνεται

σε περιόδους πνευματικής κόπωσης [48]. Επιπλέον, σημαντική μείωση του πλάτους του σχετίζεται με παθολογικές καταστάσεις και πιο συγκεκριμένα με ψυχικές ασθένειες, όπως η σχιζοφρένεια [49]. Στην περίπτωση μας, ωστόσο, καθώς οι συμμετέχοντες είναι υγιή άτομα, μπορεί να θεωρηθεί πως η μείωση του πλάτους του component P300 κατά τη μετάβαση από την ακινησία στην κίνηση, μπορεί οφείλεται στην αδυναμία συγκέντρωσης στο task κατά την περίοδο της κίνησης. Έχει αποδειχτεί, άλλωστε, πως μείωση του πλάτους του component P300 εντοπίζεται κατά την μείωση των επιπέδων συγκέντρωσης [50] αλλά και γενικότερα, σε σενάρια πραγματικής ζωής (real-life) [51], όπου αυξάνεται το γνωστικό φορτίο (cognitive load) λόγω της ύπαρξης των ατόμων σε μη περιορισμένο περιβάλλον. Η κίνηση των ατόμων κατά την υλοποίηση των πειραμάτων θεωρείται πως αποτελεί real-life σενάριο.

Στο Σχήμα 4.5 απεικονίζεται η μορφή των μέσων target και non-target σημάτων για όλους τους συμμετέχοντες, στα 4 διαφορετικά σενάρια κίνησης 0 m/s, 0.8 m/s, 1.6 m/s, 2 m/s. Η παρατήρηση που αναφέρθηκε παραπάνω και αφορά τη μείωση του πλάτους του P300 component του μέσου ERP σήματος επιβεβαιώνεται.




Σχήμα 4.5: Average Target and non-Target signals for the 4 different speeds: 0 m/s, 0.8 m/s, 1.6 m/s and 2 m/s


Για να είναι ακόμη πιο εμφανής η μείωση του πλάτους του P300 component του μέσου ERP σήματος, αναπαρίσταται στο επόμενο σχήμα (Σχήμα 4.6) το μέσο target και non-target σήμα για το κανάλι L10 κατά το session ακινησίας και κίνησης με τη μεγαλύτερη ταχύτητα (2 m/s).

Στη συνέχεια υλοποιήθηκε μελέτη των μέσων σημάτων στο πεδίο της συχνότητας, και συγκεκριμένα μελετήθηκε το φάσμα ισχύος τους. Πιο συγκεκριμένα, το φάσμα ισχύος (power spectrum / power spectral density) μια χρονοσειράς περιγράφει την κατανομή ισχύος σε συχνοτικά components που συνθέτουν την χρονοσειρά [52]. Άλλωστε, σύμφωνα με την ανάλυση Fourier, οποιοδήποτε φυσικό σήμα μπορεί να αποσυντεθεί σε έναν αριθμό διακριτών συχνοτήτων ή σε ένα φάσμα συχνοτήτων σε μια συνεχή περιοχή. Ο στατιστικός μέσος όρος ενός συγκεκριμένου σήματος ή είδους σήματος (συμπεριλαμβανομένου του θορύβου) όπως αναλύεται ως προς το περιεχόμενο συχνότητάς του, ονομάζεται φάσμα του.

Επισημαίνεται πως το πλάτος του φάσματος ισχύος ενός EEG σήματος έχει βρεθεί πως αυξάνεται με την αύξηση της ταχύτητας κίνησης του ατόμου [22]. Η αύξηση αυτή εντοπίζεται και στα ear-EEG σήματα που μελετώνται στα πλαίσια της παρούσας διπλωματικής εργασίας και παρουσιάζεται στο Σχήμα 4.7, όπου απεικονίζεται το φάσμα ισχύος των μέσων target και non-target σημάτων κατά τα sessions ακινησίας και κίνησης με τη μεγαλύτερη ταχύτητα (2 m/s).



Σχήμα 4.6: Average Target and non-Target signals for the speeds: 0 m/s and 2 m/s




Σχήμα 4.7: Power Spectral Densities of average Target and Non-Target signals for speeds: 0 m/s and 2 m/s

Κεφάλαιο 5

Παρουσίαση της μεθόδου

Στο σημείο αυτό παρουσιάζεται ένα διάγραμμα ροής, το οποίο συνοψίζει επιγραμματικά όλα τα βήματα της μεθοδολογίας που εφαρμόστηκε στα πλαίσια εκπόνησης της παρούσας διπλωματικής εργασίας, ενώ στο παρόν κεφάλαιο και στο επόμενο περιγράφονται λεπτομερώς τα επιμέρους βήματα.




Σχήμα 5.1: Διάγραμμα Ροής

5.1 Προεπεξεργασία σημάτων (Preprocessing)

5.1.1 Αρχικός Αριθμός Σημάτων ear-EEG

Όπως έχει, ήδη, αναφερθεί, τα 17 άτομα συμμετείχαν σε όλα τα sessions κίνησης και τα 7 σε όλα εκτός από το ελαφρύ τρέξιμο. Το session της ακινησίας υλοποιήθηκε 2 φορές για όλα τα άτομα. Ο αριθμός των δοκιμών (trials) για κάθε session κίνησης είναι σχεδόν για όλα τα άτομα ίσος με 300. Εξάιρεση αποτελούν τα 4 sessions κίνησης του 11ου ατόμου, ένα session κίνησης του 13ου ατόμου και ένα του 15ου, για τα οποία ο αριθμός των trials είναι ίσος με τα δύο τρίτα του κανονικού αριθμού, λόγω δυσλειτουργίας επικοινωνίας της συσκευής, δηλαδή ίσος με 200. Συνεπώς, ο συνολικός αριθμός αρχικών σημάτων ear-EEG είναι ίσος με $17 * 5 * 300 + 7 * 4 * 300 - 4 * 100 - 2 * 200 = 33300$ σήματα.

Παρατηρώντας τη μορφή των ear-EEG σημάτων, εντοπίστηκαν και κάποιες επιπλέον προβληματικές καταγραφές (πέρα από αυτές που αφαιρέθηκαν σε προηγούμενο στάδιο) σε σήματα καναλιών ορισμένων δοκιμών (trials). Στο Σχήμα 5.2 παρουσιάζεται στο πάνω μέρος η μορφή ενός κανονικοποιημένου φυσιολογικού σήματος που προέκυψε για κάποιο συγκεκριμένο trial ενός ατόμου στο κανάλι L1, ενώ στο κάτω μέρος η μορφή κάποιων κανονικοποιημένων προβληματικών καταγραφών για το ίδιο κανάλι.



Σχήμα 5.2: Problematic recordings

Κρίθηκε απαραίτητη η ανάπτυξη ελέγχου προκειμένου να εντοπιστούν όλες αυτές οι παραμένουσες προβληματικές καταγραφές, ώστε να εφαρμοστεί απομάχυνσή τους και να βελτιωθεί η ποιότητα των δεδομένων. Για την επίτευξη του σκοπού αυτού εφαρμόστηκαν δύο διαφορετικές μέθοδοι. Η πρώτη αφορά τη χρησιμοποίηση ενός μεγέθους στατιστικής ανάλυσης, και συγκεκριμένα της τυπικής απόκλισης (standard deviation/ σ), ενώ η δεύτερη τη χρησιμοποίηση του αλγορίθμου χωρικής ομαδοποίησης εφαρμογών με θόρυβο βάσει πυκνότητας (DBSCAN).

Χρήση του μεγέθους της τυπικής απόκλισης

Η τυπική απόκλιση (standard deviation / σ) μετρά πόσο αποκλίνει ένα παρατηρούμενο σήμα από τον μέσο όρο. Όταν ένα σήμα θα παρουσιάσει τυπική απόκλιση πολύ μεγαλύτερη από την τυπική

απόκλιση που παρουσιάζουν τα υπόλοιπα σήματα, τότε συνάγεται το συμπέρασμα πως έχει μεγαλύτερο πλάτος και είναι πιθανό αυτό να αποτελεί προβληματική καταγραφή. Η αναλυτική διαδικασία που ακολουθήθηκε παρουσιάζεται επεξηγηματικά παρακάτω.

Για κάθε άτομο, μελετήθηκαν τα σήματα του κάθε καναλιού ξεχωριστά για κάθε trial σε κάθε session κίνησης. Ουσιαστικά, για κάθε trial κάθε καναλιού υπολογίστηκε η τυπική απόκλιση όλων των σημάτων του. Επιπλέον, υπολογίστηκε η μέση τιμή των 100 μικρότερων τυπικών αποκλίσεων που προέκυψαν στο συγκεκριμένο session κίνησης όπου ανήκει (θέτοντας ως προϋπόθεση πως τουλάχιστον τα 100 απ' τα 200/300 trials που παρουσιάζονται σε κάθε session θεωρούνται αποδεκτά σήματα) – έστω πως η τιμή αυτή είναι ίση με σ . Τελικά, θεωρήθηκαν μη προβληματικά όλα εκείνα τα σήματα που είχαν τυπική απόκλιση μικρότερη από 3σ – η τιμή αυτή δεν θεωρείται πολύ αυστηρός περιορισμός. Αποτέλεσμα της διαδικασίας αυτής ήταν να εντοπιστούν όλα τα προβληματικά σήματα που είχαν πολύ μεγάλο πλάτος, αλλά η χρήση αυτής της μεθόδου περιορίζεται μόνο στον εντοπισμό αυτών των σημάτων και μπορεί να οδηγήσει και σε λανθασμένα συμπεράσματα, καθώς δεν είναι βέβαιο πως όλα τα σήματα αυτά είναι απαραίτητα προβληματικά.

Συνοψίζοντας, η αρχική ενέργεια χρησιμοποίησης της εν λόγω μεθόδου δεν θεωρείται η βέλτιστη δυνατή, μιας και εντοπίζει ένα συγκεκριμένο είδος προβληματικών σημάτων. Για τον λόγο αυτό, επιχειρήθηκε η υλοποίηση του επόμενου ελέγχου με χρήση του αλγορίθμου ομαδοποίησης (clustering) DBSCAN, αναμένοντας πως θα οδηγήσει στον διαχωρισμό των προβληματικών σημάτων (outliers) σε διαφορετικές ομάδες από τα φυσιολογικά σήματα.


Χρήση του αλγορίθμου ομαδοποίησης DBSCAN

Έγινε χρησιμοποίηση αλγορίθμου ομαδοποίησης επειδή αναμένεται πως τα φυσιολογικά σήματα θα κατηγοριοποιηθούν στην ίδια ομάδα, μιας και έχουν κοινά χαρακτηριστικά, ενώ τα προβληματικά σήματα θα δημιουργήσουν άλλες ομάδες, και έτσι θα οδηγηθούμε σε απομόνωση των φυσιολογικών σημάτων. Αφού δεν είναι δυνατό να υπάρχει γνώση του αριθμού των διαφορετικών ομάδων που μπορεί να δημιουργήσει η διαφορετική φύση των μη φυσιολογικών σημάτων (outliers), δεν γίνεται να καθοριστεί εκ των προτέρων ο αριθμός των ομάδων που θα δημιουργηθούν συνολικά. Γνωρίζοντας πως ο αλγόριθμος DBSCAN δεν απαιτεί προγενέστερη γνώση του αριθμού των ομάδων που χρειάζεται να δημιουργηθούν, θεωρήθηκε κατάλληλος να χρησιμοποιηθεί.

Πιο συγκεκριμένα, με χρήση του αλγορίθμου πραγματοποιήθηκε χωρική ομαδοποίηση των σημάτων κάθε καναλιού για κάθε session κάθε ατόμου. Εντοπίστηκε η ομάδα που αποτελούταν από τα φυσιολογικά σήματα (η οποία, προφανώς, περιείχε σε κάθε περίπτωση μεγαλύτερο αριθμό σημάτων) και υπολογίστηκε ο αριθμός των μη φυσιολογικών σημάτων που προέκυπταν για κάθε κανάλι. Αποφασίστηκε να αριθμηθεί ο αριθμός των trials για τα οποία προέκυπταν μη φυσιολογικά σήματα για ένα ή περισσότερα κανάλια. Στο Σχήμα 5.3 παρουσιάζεται το ποσοστό των trials όπου παρατηρούνταν τα προβληματικά σήματα για ένα τουλάχιστον κανάλι για κάθε έναν από τους 24 συμμετέχοντες.

Ακόμη, υπολογίστηκε το συνολικό ποσοστό των προβληματικών δοκιμών (trials) για τουλάχιστον ένα κανάλι ως προς το σύνολο των δεδομένων, προκειμένου να αποφασιστεί αν η απόρριψή τους θα δημιουργήσει σημαντική απώλεια πληροφορίας. Το ποσοστό αυτό φαίνεται στο Σχήμα 5.4.

Καθώς η τιμή του ποσοστού αυτού είναι μικρότερη από 5%, θεωρείται πως η απόρριψη των σημάτων σε κάθε κανάλι για αυτές τις δοκιμές (trials) δεν προκαλεί υποβάθμιση των δεδομένων και



Σχήμα 5.3: Ποσοστό trials με προβληματικά σήματα


Total Losses of trials
3.78%

Σχήμα 5.4: Ποσοστό προβληματικών trials

είναι δυνατό να υλοποιηθεί η ενέργεια αυτή, χωρίς να θεωρείται απαραίτητη η χρήση παρεμβολής (interpolation).

5.2 Εφαρμογή αποσύνθεσης Σμήνους

Την προηγούμενη προεπεξεργασία ακολουθεί η εφαρμογή Αποσύνθεσης Σμήνους για κάθε ένα από τα σήματα κάθε καναλιού ξεχωριστά, ενώ πριν την εφαρμογή της, τα σήματα κανονικοποιούνται με αφαίρεση της μέσης τιμής τους και διαίρεση με την τυπική τους απόκλιση. Στο Σχήμα 5.5 παρουσιάζεται η μορφή δύο σημάτων του καναλιού L1 μιας δοκιμής του πρώτου συμμετέχοντα, τα οποία προέκυψαν κατά το session της ακινησίας και κατά το session κίνησης με 2 m/s. Πιο συγκεκριμένα απεικονίζονται τα αρχικά σήματα στο πεδίο του χρόνου (initial signal time-domain), τα κανονικοποιημένα αυτών (normalized initial signal time-domain) και τα σήματα στο πεδίο της συχνότητας (initial signal frequency-domain). Στο πεδίο της συχνότητας έχουμε κανονικοποίηση του οριζόντιου άξονα, και η μονάδα είναι ίση με $F_s/2$, όπου F_s είναι η συχνότητα δειγματοληψίας, ίση με 100 Hz.



Σχήμα 5.5: Initial Signals in time and frequency domain

Οι παράμετροι που χρησιμοποιήθηκαν για την υλοποίηση της αποσύνθεσης σμήνους παρουσιάζονται στο Σχήμα 5.6.

Παράμετροι SWD	Τιμές
Pth (κατώφλι επιλογής κορυφών)	0.01
Welch_window (το παράθυρο του φίλτρου)	50 [0.5 * μήκος_σήματος]
Welch_overlap (ο δείκτης επικάλυψης φίλτρου)	25 (50 %)
Welch_nfft (ο αριθμός των διακριτών σημείων του μετασχηματισμού Fourier)	64
StDth (κατώφλι απόκλισης)	0.1


Σχήμα 5.6: SWD Parameters

Για κάθε σήμα προκύπτει ένας αριθμός συχνοτικών συνιστωσών (Oscillatory Modes), αριθμός ο οποίος δεν είναι απαραίτητα ίδιος για όλα τα σήματα, λόγω της διαφορετικής μορφής τους. Επισημαίνεται πως ο αριθμός των συχνοτικών συνιστωσών δεν είναι ίδιος ούτε για σήματα άλλων καναλιών της ίδιας δοκιμής του ίδιου session κίνησης.

Στο Σχήμα 5.7 απεικονίζεται η διαδικασία Αποσύνθεσης Σμήνους των δύο σημάτων για τα οποία έγινε λόγος παραπάνω. Στο αριστερό μέρος των υποσχημάτων παρουσιάζονται οι συνιστώσες (Oscillatory Modes) στο πεδίο του χρόνου, ενώ στο δεξί στο πεδίο της συχνότητας. Παρατηρείται, όπως σχολιάστηκε παραπάνω, ότι ο αριθμός των συχνοτικών συνιστωσών για τα δύο σήματα διαφέρει.

Καθώς δεν είναι δυνατόν να υπάρχει πρότερη γνώση για το αν κάποια συχνοτική συνιστώσα περιέχει σήμα EEG, αν περιέχει μόνο moving artifacts ή αν περιέχει και τα δύο, δεν ήταν εύκολο να αποφασιστεί ποιες συχνοτικές συνιστώσες είναι οι πιο χρήσιμες. Γί αυτό, αποφασίστηκε πως θα αξιοποιηθεί η πληροφορία από όλες. Όπως, όμως, αναφέρθηκε αλλά και φάνηκε στο προηγούμενο σχήμα, δεν είναι κοινός ο αριθμός των συχνοτικών συνιστωσών για όλα τα σήματα. Επιδιώκοντας να υπάρχει ίδιος αριθμός συχνοτικών συνιστωσών, που θα είναι και γνωστός, επιλέχτηκε να αθροιστούν οι συχνοτικές συνιστώσες που ανήκουν σε περιοχή με γειτονική κεντρική συχνότητα. Πιο συγκεκριμένα, το συχνοτικό φάσμα χωρίζεται σε 4 ίσες περιοχές και κάθε συχνοτική συνιστώσα κατατάσσεται σε μια από τις 4 περιοχές βάσει της κεντρικής της συχνότητας.

- Αν η κεντρική συχνότητα ανήκει στο διάστημα $[0, F_s/8]$, δηλαδή στην συχνοτική περιοχή $[0, 12.5 \text{ Hz}]$, η συχνοτική συνιστώσα τοποθετείται στην πρώτη περιοχή.
- Αν η κεντρική συχνότητα ανήκει στο διάστημα $[F_s/8, F_s/4]$, δηλαδή στην συχνοτική περιοχή $[12.5, 25 \text{ Hz}]$, η συχνοτική συνιστώσα τοποθετείται στην δεύτερη περιοχή.




Σχήμα 5.7: Oscillatory Modes after Swarm Decomposition

- Αν η κεντρική συχνότητα ανήκει στο διάστημα $[F_s/4, 3F_s/8]$, δηλαδή στην συχνοτική περιοχή $[25, 37.5 \text{ Hz}]$, η συχνοτική συνιστώσα τοποθετείται στην τρίτη περιοχή.
- Αν η κεντρική συχνότητα ανήκει στο διάστημα $[3F_s/8, F_s/2]$, δηλαδή στην συχνοτική περιοχή $[37.5, 50 \text{ Hz}]$, η συχνοτική συνιστώσα τοποθετείται στην τέταρτη περιοχή.

Στη συνέχεια, όλες οι συχνοτικές συνιστώσες (OMs) κάθε περιοχής αθροίζονται, και τελικά για κάθε σήμα προκύπτουν 4 τελικές συχνοτικές συνιστώσες. Στο Σχήμα 5.8 παρουσιάζονται οι τέσσερις τελικές συνιστώσες που προκύπτουν για τα δύο σήματα που αναφέρθηκαν παραπάνω. Σημειώνεται ότι κάθε συχνοτική συνιστώσα έχει μέγεθος ίσο με 129 δείγματα (samples) και συνεπώς, για κάθε σήμα προκύπτουν 4 συχνοτικές συνιστώσες 129 δειγμάτων (προφανώς ίσο με $2 * Welch_{nfft} + 1$).

Ως επόμενο βήμα, επιδιώκεται να γίνει συλλογή της συνολικής πληροφορίας για κάθε δοκιμή (trial) κάθε session κίνησης, ώστε να εισαχθεί σε επόμενο βήμα όλη μαζί σε συνελικτικό νευρωνικό δίκτυο, με σκοπό αυτό να εκπαιδευτεί ώστε να προβλέπει αν το trial ανήκει σε session κίνησης ή ακινησίας. Γι' αυτό, συλλέγονται όλες οι τελικές συχνοτικές συνιστώσες των σημάτων και των 14 ear-EEG καναλιών. Η τελική μορφή που έχουν τα δεδομένα του κάθε trial που εισάγονται στο νευρωνικό δίκτυο είναι $129 \times 14 \times 4$ (samples $\times$ channels $\times$ Oscillatory Modes).



Σχήμα 5.8: Oscillatory Modes after Swarm Decomposition

Κεφάλαιο 6

Δημιουργία Συνελικτικού Μοντέλου

Προτού αναλυθούν τα βήματα που ακολουθούνται για τη δημιουργία του μοντέλου, κρίνεται απαραίτητο να επισημανθεί ο σκοπός δημιουργίας του. Ουσιαστικά, επιδιώκεται μετά την εκπαίδευση και την αξιολόγηση του μοντέλου, να είναι ικανό να προβλέπει με υψηλό ποσοστό ακρίβειας αν τα δεδομένα που εισάγονται σε αυτό, προέρχονται από σήματα ear-EEG που προέκυψαν όσο το άτομο ήταν ακίνητο ή κινούταν. Με άλλα λόγια, σκοπός αποτελεί η ταξινόμηση (classification) των εισερχόμενων σημάτων σε αυτά που προκύπτουν κατά την ακινησία του ατόμου και σε αυτά που προκύπτουν όσο αυτό κινείται (με ταχύτητα ίση με 0.8 m/s, 1.6 m/s ή 2 m/s). Την είσοδο του μοντέλου αποτελεί το σύνολο της πληροφορίας από όλα τα κανάλια για κάθε δοκιμή και έχει μορφή, όπως έχει ήδη αναφερθεί, $129 \times 14 \times 4$ (samples $\times$ channels $\times$ Oscillatory Modes). Ανάλογα με το αν η πληροφορία που προκύπτει από το δεδομένο trial προέρχεται από session ακινησίας ή κίνησης, η έξοδος έχει μορφή ίση με 0 ή 1, όπου το 0 αντιστοιχεί σε ακινησία και το 1 σε κίνηση.

6.1 Δημιουργία των συνόλων εκπαίδευσης, επικύρωσης και δοκιμής

Σαν πρώτο βήμα, το αρχικό σύνολο των δεδομένων για τα trials των target και non-target σημάτων όλων των συμμετεχόντων χωρίζεται σε τρία υποσύνολα, τα οποία αποτελούν το σύνολο εκπαίδευσης (training set), το σύνολο επικύρωσης (validation set) και το σύνολο δοκιμής (test set) για το συνελικτικό δίκτυο. Στο σημείο αυτό, τονίζεται πως τα δεδομένα που προκύπτουν από έναν δεδομένο συμμετέχοντα χρησιμοποιούνται όλα στο ίδιο υποσύνολο. Επιθυμείται να υπάρχει ισορροπία (balance) στα δεδομένα κίνησης και ακινησίας σε όλα τα υποσύνολα, δηλαδή να είναι περίπου ίσα σε αριθμό μεταξύ τους για το καθένα. Ακόμη, σημειώνεται πως επιλέχτηκε μια τυπική αναλογία διαχωρισμού για τα σύνολα εκπαίδευσης, επικύρωσης και δοκιμής, η οποία είναι ίση με 50:25:25. Δηλαδή, το μέγεθος του συνόλου εκπαίδευσης είναι διπλάσιο των άλλων δύο.

Σύνολο Εκπαίδευσης (Training Set): Αποτελείται από τα δεδομένα των συμμετεχόντων 13 - 24 (συνολικά 12 ατόμων). Επειδή, όμως, τα trials κίνησης είναι περισσότερα, μιας και τα sessions κίνησης είναι περισσότερα από της ακινησίας (δύο έναντι τριών), αποφασίστηκε να μη ληφθούν υπόψιν τα δεδομένα της κίνησης με ταχύτητα 0.8 m/s των ατόμων 20 - 24, ώστε να εφαρμοστεί

balancing για τις δύο κλάσεις ταξινόμησης (ακινήσια και κίνηση). Υπενθυμίζεται ότι τα άτομα 18 - 24 δεν συμμετείχαν, ούτως ή άλλως, στο session κίνησης με 2 m/s. Τελικά, ο αριθμός των εισόδων που αντιστοιχούν σε ακινήσια και σε κίνηση είναι 6851 και 6847 αντίστοιχα. Στο Σχήμα 6.1 παρουσιάζεται η ισορροπία των δεδομένων του συνόλου εκπαίδευσης.



Σχήμα 6.1: Balance of the training set

Σύνολο Επικύρωσης (Validation Set): Αποτελείται από τα δεδομένα των συμμετεχόντων 6, 8 - 12 (συνολικά 6 ατόμων). Για λόγους balancing των δεδομένων που αντιστοιχούν στις δύο κλάσεις ταξινόμησης (ακινήσια και κίνηση), αποφασίστηκε να μη ληφθούν υπόψιν τα δεδομένα της κίνησης με ταχύτητα 0.8 m/s όλων των ατόμων του συνόλου. Τελικά, ο αριθμός των εισόδων που αντιστοιχούν σε ακινήσια και σε κίνηση είναι 3481 και 3472 αντίστοιχα. Στο Σχήμα 6.2 παρουσιάζεται η ισορροπία των δεδομένων του συνόλου επικύρωσης.

Σύνολο Δοκιμής (Test Set): Αποτελείται από τα δεδομένα των συμμετεχόντων 1 - 5, 7 (συνολικά 6 ατόμων). Για λόγους balancing των δεδομένων που αντιστοιχούν στις δύο κλάσεις ταξινόμησης (ακινήσια και κίνηση), αποφασίστηκε να μη ληφθούν υπόψιν τα δεδομένα της κίνησης με ταχύτητα 0.8 m/s όλων των ατόμων του συνόλου. Τελικά, ο αριθμός των εισόδων που αντιστοιχούν σε ακινήσια και σε κίνηση είναι 3451 και 3403 αντίστοιχα. Στο Σχήμα 6.3 παρουσιάζεται η ισορροπία των δεδομένων του συνόλου δοκιμής.

Προκειμένου να γίνει φανερή η αναλογία των μεγεθών των συνόλων, απεικονίζεται στο Σχήμα 6.4 το συνολικό μέγεθος του καθενός από αυτά.

6.2 Δομή του Συνελικτικού Δικτύου

Όπως έχει αναφερθεί και σε προηγούμενη ενότητα, επιδιώκεται να γίνει χρήση χρήση συνελικτικών δικτύων με σχετικά μικρό βάθος (σχετικά μικρός αριθμός επιμέρους επιπέδων) καθώς επιδιώκεται η διατήρηση μικρού χρόνου εκπαίδευσης και πολυπλοκότητας, αλλά και επιβεβαίωση πως η χρήση αποσύνθεσης σμήνους βοηθά στην ευκολότερη αναγνώριση προτύπων για τα σήματα που προκύπτουν όταν τα άτομα βρίσκονταν σε διαφορετική κινητική κατάσταση.




Σχήμα 6.2: Balance of the validation set



Σχήμα 6.3: Balance of the test set

Δημιουργείται, λοιπόν, ένα συνελικτικό δίκτυο που αποτελείται από μόλις δύο συνελικτικά επίπεδα (convolutional layers) και ένα πλήρως συνδεδεμένο επίπεδο (fully connected layer). Μετά το πρώτο συνελικτικό επίπεδο τοποθετείται ένα επίπεδο υποδειγματοληψίας και συγκεκριμένα, ένα επίπεδο max pooling με μέγεθος φίλτρου και άλμα φίλτρου ίσα με 2. Ακόμη, σε κάθε επίπεδο του δικτύου χρησιμοποιούνται δύο επίπεδα κανονικοποίησης παρτίδας (batch normalization layers) που ακολουθούνται από δύο επίπεδα αποκοπής νευρώνων (dropout layers) με ρυθμό εγκατάλειψης ίσο με 0.25. Πριν το πλήρες συνδεδεμένο επίπεδο, τοποθετείται ένα flatten layer ώστε να μετατρέψει την πολυδιάστατη είσοδό του σε μονοδιάστατη, η οποία θα εισαχθεί στο πλήρες συνδεδεμένο επίπεδο. Η συνάρτηση ενεργοποίησης που χρησιμοποιείται στην έξοδο του νευρωνικού δικτύου είναι η softmax για να παράξει σαν έξοδο δύο τιμές πιθανότητας, όπου η πρώτη αναπαριστά την πιθανότητα η είσοδος



Σχήμα 6.4: Μέγεθος των συνόλων

του δικτύου να αντιστοιχεί σε session ακινησίας, ενώ η δεύτερη την πιθανότητα να αντιστοιχεί σε session κίνησης.

Εφαρμόζεται hyper parameter tuning για τον υπολογισμό έξι βασικών παραμέτρων του δικτύου. Αυτές είναι το μέγεθος του φίλτρου και του βήματος φίλτρου των δύο συνελκτικών επιπέδων, ο αριθμός των νευρώνων του πλήρως συνδεδεμένου επιπέδου και ο ρυθμός μάθησης του μοντέλου (learning rate). Για το μέγεθος των φίλτρων εξετάστηκαν οι τιμές που ανήκουν στο διάστημα [32, 128] με βήμα 16, ενώ για το μέγεθος των βημάτων των φίλτρων εξετάστηκαν οι τιμές που ανήκουν στο διάστημα [3, 5]. Για τον αριθμό των νευρώνων του τελευταίου επιπέδου εξετάστηκαν οι τιμές [32, 128] με βήμα 16, ενώ για τον ρυθμό μάθησης οι τιμές 0.01 και 0.001. Μέσω του hyper parameter tuning, λοιπόν, αναζητούνται οι τιμές των εν λόγω παραμέτρων που δημιουργούν μοντέλο με την καλύτερη απώλεια επικύρωσης, δηλαδή, με άλλα λόγια, το μικρότερο validation loss. Ο μέγιστος αριθμός εποχών (epochs) που χρησιμοποιούνται για την εκπαίδευση του δικτύου είναι 50, αλλά παράλληλα, με σκοπό να αποφευχθεί η υπερεκπαίδευση (overtraining), υλοποιείται πρόωρη διακοπή (early stopping) της εκπαίδευσης του δικτύου όταν η απώλεια επικύρωσης δεν βελτιώνεται για πάνω από τρεις διαδοχικές εποχές. Οι τελικές παράμετροι που θεωρούνται βέλτιστοι, αφού δίνουν την μικρότερη απώλεια επικύρωσης, παρουσιάζονται στο Σχήμα 6.5.


Μέγεθος Φίλτρου 1 ^{ου} Συνελκτικού Επιπέδου	80
Βήμα Φίλτρου 1 ^{ου} Συνελκτικού Επιπέδου	5
Μέγεθος Φίλτρου 2 ^{ου} Συνελκτικού Επιπέδου	80
Βήμα Φίλτρου 2 ^{ου} Συνελκτικού Επιπέδου	5
Αριθμός Νευρώνων Πλήρως Συνδεδεμένου Επιπέδου	128
Ρυθμός Μάθησης	0.001

Σχήμα 6.5: Παράμετροι που προέκυψαν μετά την εφαρμογή του hyper parameter tuning

6.3 Αξιολόγηση του Συνελικτικού Δικτύου

Μετά τον εντοπισμό των βέλτιστων παραμέτρων, δημιουργείται μοντέλο που έχει την επιθυμητή δομή, το οποίο εκπαιδεύεται με μέγιστο αριθμό εποχών ίσο με 50 και ταυτόχρονη χρήση πρόωρης διακοπής όταν η απώλεια επικύρωσης δεν βελτιώνεται για πάνω από τρεις διαδοχικές εποχές. Η τελική απώλεια επικύρωσης του δικτύου προέκυψε σχεδόν ίση με την προηγούμενως υπολογισμένη βέλτιστη απώλεια επικύρωσης (απόκλιση μόλις 0.02).

Στη συνέχεια, το μοντέλο αξιολογείται μέσω μελέτης της απόδοσής του στο σύνολο δοκιμής. Η ακρίβεια δοκιμής (test accuracy) και η απώλεια δοκιμής (test loss) φαίνονται στο Σχήμα 6.6. Παράλληλα, επισημαίνεται ότι η ακρίβεια εκπαίδευσης (training accuracy) στην τελευταία εποχή προκύπτει ίση με 0.91 (ή 91%), δηλαδή είναι μόλις 3% καλύτερη από την ακρίβεια δοκιμής. Για το λόγο αυτό, μπορεί να θεωρηθεί πως επιτεύχθηκε η αποφυγή υπερεκπαίδευσης του μοντέλου.




Σχήμα 6.6: Ακρίβεια και απώλεια για το σύνολο δοκιμής

Ακολουθεί ο υπολογισμός του πίνακα σύγχυσης (confusion matrix) του μοντέλου, ώστε να γίνει οπτικά καταφανής ο αριθμός των σωστών και λάθος προβλέψεων για τις δύο κατηγορίες ταξινόμησης, ακινησίας (κλάση με ένδειξη 0) και κίνησης (κλάση με ένδειξη 1). Φαίνεται πως προβλέπει τις δύο κλάσεις με σχεδόν την ίδια απόδοση (Σχήμα 6.7).

Επιπλέον, παρουσιάζεται η αναφορά ταξινόμησης (classification report) του μοντέλου, όπου συμπεριλαμβάνονται οι υπόλοιπες μετρικές αξιολόγησης του μοντέλου, δηλαδή η αξιοπιστία (precision), η ανάκληση (recall) και ο παράγοντας F1 (Σχήμα 6.8).

Πολύ σημαντική μετρική για την αξιολόγηση του μοντέλου, όπως έχει ήδη αναφερθεί στο Κεφάλαιο 3, αποτελεί η ROC καμπύλη (Σχήμα 6.9). Η τιμή AUC υπολογίζεται ίση με 0.939, πράγμα που αποδεικνύει πως το μοντέλο πετυχαίνει σε πολύ ικανοποιητικό βαθμό την ταξινόμηση στις κλάσεις ακινησίας και κίνησης.




Σχήμα 6.7: Πίνακας σύγχυσης

	precision	recall	F1 - score	support
Ακίνησία (κλάση 0)	0.88	0.89	0.88	3451
Κίνηση (κλάση 1)	0.89	0.87	0.88	3403
accuracy			0.88	6854
Macro average	0.88	0.88	0.88	6854
Weighted average	0.88	0.88	0.88	6854

Σχήμα 6.8: Classification Report

6.4 Διαστήματα Εμπιστοσύνης για τις μετρικές του μοντέλου

Ένα διάστημα εμπιστοσύνης (confidence intervals) είναι μια μέθοδος που υπολογίζει ένα άνω και ένα κάτω όριο γύρω από μια εκτιμώμενη τιμή μιας συγκεκριμένης παραμέτρου. Η πραγματική τιμή της παραμέτρου βρίσκεται είτε εντός είτε εκτός αυτών των ορίων [53]. Είναι μια κοινή σύμβαση να χρησιμοποιείται ένα διάστημα εμπιστοσύνης 95%. Αυτό, πρακτικά, ερμηνεύεται πως δεδομένης μια συγκεκριμένης κατανομής και ενός πολύ μεγάλου αριθμού δειγμάτων αυτής, αν ληφθούν 100 διαφορετικά δείγματα και υπολογιστούν τα διαστήματα εμπιστοσύνης για κάθε ένα από αυτά, τα 95 θα περιέχουν την πραγματική τιμή [54].



Σχήμα 6.9: ROC καμπύλη

Στη δεδομένη περίπτωση αξιολόγησης της απόδοσης του συνελικτικού μοντέλου, η κύρια παράμετρος που έχει, ήδη, εκτιμηθεί είναι η ακρίβεια (accuracy). Το διάστημα εμπιστοσύνης δίνει ένα μέτρο βεβαιότητας για το πόσο ακριβής είναι η εκτίμηση της ακρίβειας. Άλλες βασικές μετρικές αξιολόγησης για τις οποίες αναζητάται η βεβαιότητα για την ακρίβεια της τιμής τους, που έχει υπολογιστεί προηγουμένως, είναι η αξιοπιστία (precision), η ανάκληση (recall) και ο παράγοντας F1.

Μεταξύ των διαθέσιμων μεθόδων που χρησιμοποιούνται για τον υπολογισμό των διαστημάτων εμπιστοσύνης, έγινε επιλογή χρησιμοποίησης των δύο φθηνότερων από άποψη πόρων, γιατί οι δεδομένες μέθοδοι αποφεύγουν πιθανή επανεκπαίδευση (retraining) του μοντέλου [53]. Αυτές είναι:

- η μέθοδος κανονικής προσέγγισης διαστημάτων (normal approximation method)
- η μέθοδος bootstrapping του συνόλου δοκιμής (bootstrapping the test set).

Η μέθοδος (bootstrapping) του συνόλου δοκιμής απαιτεί πρόσβαση στις προβλέψεις του συνόλου δοκιμής του μοντέλου, ενώ η μέθοδος κανονικής προσέγγισης διαστημάτων μπορεί να υπολογιστεί κατευθείαν από την υπολογισμένη τιμή της μετρικής.

6.4.1 Μέθοδος κανονικής προσέγγισης διαστημάτων

Υποθέτοντας πως η εκτιμώμενη παράμετρος είναι η ακρίβεια (accuracy) του μοντέλου (ας την ονομάσουμε ACC_{test}) ακολουθεί κανονική κατανομή, η εξίσωση του διαστήματος εμπιστοσύνης για αυτήν ορίζεται ως εξής: $ACC_{test} \pm z \times SE$, όπου

- z ο αριθμός των τυπικών αποκλίσεων που η παράμετρος απέχει από το μέσο όρο μιας τυπικής κανονικής κατανομής, και
- SE είναι το τυπικό σφάλμα (Standard Error) της εκτιμώμενης παραμέτρου

Το τυπικό σφάλμα μια κανονική κατανομής μπορεί να υπολογιστεί ως: $SE = \sqrt{\frac{1}{n} ACC_{test}(1 - ACC_{test})}$, όπου n είναι το μέγεθος του συνόλου δοκιμής. Άρα, τελικά το ζητούμενο διάστημα εμπιστοσύνης δίνεται ως εξής: $ACC_{test} \pm z \sqrt{\frac{1}{n} ACC_{test}(1 - ACC_{test})}$.

6.4.2 Μέθοδος bootstrapping του συνόλου δοκιμής


Με τη χρήση της μεθόδου bootstrapping γίνεται λήψη πολλαπλών δειγμάτων του συνόλου δοκιμής με αντικατάσταση κάθε φορά ενός τυχαίου δείγματος με ένα άλλο, και υπολογίζεται η μετρική του μοντέλου για το δημιουργούμενο σύνολο δοκιμών. Η ίδια διαδικασία επαναλαμβάνεται πολλές φορές ώστε τελικά να υπολογιστεί η μέση τιμή της μετρικής του μοντέλου. Αν επιθυμείται να υπολογιστεί η ακρίβεια, η μέση τιμή της που προκύπτει με τη χρήση της μεθόδου δίνεται από την ακόλουθη εξίσωση: $ACC_{bootavg} = \frac{1}{b} \sum_{j=1}^b ACC_{boot,j}$, όπου b είναι ο συνολικός αριθμός των επαναλήψεων bootstrapping που υλοποιούνται και το $ACC_{boot,j}$ είναι η ακρίβεια του μοντέλου που υπολογίζεται στην j -ιστή επανάληψη. Σημειώνεται πως προτείνεται ο αριθμός επαναλήψεων της διαδικασίας προτείνεται να είναι τουλάχιστον ίσος με 200 [55]. Κατά την εφαρμογή της μεθόδου bootstrapping στα πλαίσια της παρούσας διπλωματικής εργασίας αναφέρεται πως υλοποιήθηκαν 500 επαναλήψεις.

Έχοντας αναλύσει τα βήματα της εν λόγω διαδικασίας γίνεται λόγος για τα διαστήματα εμπιστοσύνης που προκύπτουν με τη χρήση αυτής. Υποθέτοντας πως η εκτιμώμενη παράμετρος είναι η ακρίβεια (accuracy) του μοντέλου (ας την ονομάσουμε ACC_{test}) ακολουθεί κανονική κατανομή, η εξίσωση του διαστήματος εμπιστοσύνης για αυτήν μπορεί να υπολογιστεί, όπως και πριν, ως: $ACC_{test} \pm z \times SE$, όπου το SE (Standard Error) δίνεται από την εξίσωση:


$SE = \sqrt{\frac{1}{b-1} \sum_{j=1}^b ACC_{boot,j}(1 - ACC_{bootavg})^2}$. Συνήθως, για να υπολογιστεί το SE διαιρείται η τυπική απόκλιση (Standard Deviation - SD) με $\sqrt{n}$, όπου $n = b$: $SE = \frac{SD}{\sqrt{n}}$.

6.4.3 Τελικά Διαστήματα Εμπιστοσύνης


Στην υποενότητα αυτή παρουσιάζονται τα διαστήματα εμπιστοσύνης που υπολογίστηκαν για κάθε μια από τις μετρικές του μοντέλου με τη χρήση των δύο μεθόδων που αναλύθηκαν παραπάνω. Πιο συγκεκριμένα, κάθε ένα από τα ακόλουθα σχήματα απεικονίζει τα διαστήματα εμπιστοσύνης που αφορούν μία συγκεκριμένη μετρική.




Σχήμα 6.10: Διαστήματα Εμπιστοσύνης για την Ακρίβεια του μοντέλου



Σχήμα 6.11: Διαστήματα Εμπιστοσύνης για την Αξιοπιστία του μοντέλου



Σχήμα 6.12: Διαστήματα Εμπιστοσύνης για την Ανάκληση του μοντέλου



Σχήμα 6.13: Διαστήματα Εμπιστοσύνης για τον Παράγοντα F1 του μοντέλου

6.5 Αξιολόγηση της πληροφορίας που οδηγεί το Συνελικτικό Δίκτυο στην Απόφαση


Αποφασίστηκε να γίνει μια προσπάθεια εντοπισμού της πληροφορίας εισόδου του συνελικτικού δικτύου που οδηγεί το μοντέλο στη λήψη απόφασης (περίπτωση ακινησίας ή κίνησης) με μεγαλύτερη ακρίβεια. Για το λόγο αυτό, υλοποιήθηκε αλλοίωση της μορφής του συνόλου δοκιμής (test set) και

υπολογίστηκε η ακρίβεια με την οποία το ήδη εκπαιδευμένο δίκτυο προβλέπει την επιθυμητή έξοδο. Περαιτέρω λεπτομέρειες για το είδος της αλλοίωσης του συνόλου δοκιμής που υλοποιείται κάθε φορά αναφέρονται παρακάτω. Υπενθυμίζεται ότι τα δεδομένα εισόδου του δικτύου έχουν μορφή $129 \times 14 \times 4$ (samples $\times$ channels $\times$ Oscillatory Modes).

6.5.1 Εντοπισμός της συχνοτικής περιοχής των Oscillatory Modes που προσφέρει την πιο χρήσιμη πληροφορία

Αρχικά, πραγματοποιείται αλλοίωση του συνόλου δοκιμής μηδενίζοντας μία μία τις συχνοτικές συνιστώσες (Oscillatory Modes) και διατηρώντας τις υπόλοιπες ανέγγιχτες. Η εν λόγω αλλοίωση αφορά, ουσιαστικά, την τρίτη διάσταση των δεδομένων εισόδου του δικτύου. Στη συνέχεια, η νέα μορφή συνόλου δοκιμής τροφοδοτείται ως είσοδος στο δίκτυο και υπολογίζεται η ακρίβεια των προβλέψεων. Στο Σχήμα 6.14 παρουσιάζονται συγκεντρωτικά τα ποσοστά ακρίβειας για τα 4 διαφορετικά σύνολα δοκιμής που δημιουργούνται. Το όνομα $XtestWithoutComp_i$ που εμφανίζεται στον οριζόντιο άξονα σημαίνει πως αποτελεί το αλλοιωμένο σύνολο δοκιμής όπου μηδενίστηκε η i_{th} συχνοτική περιοχή.


Παρατηρείται πως απώλεια της πρώτης και δεύτερης συχνοτικής περιοχής η ακρίβεια των προβλέψεων μειώνεται σημαντικά, συγκριτικά με την ακρίβεια που προκύπτει όταν το σύνολο δοκιμής είναι αναλλοίωτο.



Σχήμα 6.14: Accuracy Score

Σε επόμενο βήμα, υλοποιείται μηδενισμός όλων των συχνοτικών περιοχών του συνόλου δοκιμής εκτός από μία κάθε φορά, ώστε να είναι πιο ξεκάθαρη η συνδρομή της κάθε μιας στην απόφαση του δικτύου. Στο Σχήμα 6.15 παρουσιάζονται συγκεντρωτικά τα ποσοστά ακρίβειας για τα 4 διαφορετικά σύνολα δοκιμής που δημιουργούνται. Το όνομα $XtestOnlyComp_i$ που εμφανίζεται στον οριζόντιο άξονα σημαίνει πως αποτελεί το αλλοιωμένο σύνολο δοκιμής όπου μηδενίστηκαν όλες οι συχνοτικές περιοχές εκτός από την i_{th} . Είναι καταφανές πως, όντως, οι πρώτες δύο συχνοτικές περιοχές (και κυρίως η πρώτη) οδηγούν το δίκτυο σε λήψη ορθότερων αποφάσεων. Όπως έχει αναφερθεί παραπάνω, οι περιοχές αυτές περιλαμβάνουν το άθροισμα των συχνοτικών συνιστωσών (oscillatory

modes) που προκύπτουν μετά την εφαρμογή της αποσύνθεσης σμήνους και που έχουν κεντρική συχνότητα η οποία ανήκει στα διαστήματα $[0, 12.5 \text{ Hz}]$ και $[12.5, 25 \text{ Hz}]$ αντίστοιχα.




Σχήμα 6.15: Accuracy Score


6.5.2 Εντοπισμός των καναλιών που προσφέρουν την πιο χρήσιμη πληροφορία

Υπενθυμίζεται πως τα κανάλια που συλλέγουν τα ear-EEG σήματα από το αριστερό αυτί είναι τα κανάλια (L1, L2, L4, L5, L6, L7, L9, L10), ενώ αυτά που συλλέγουν από το δεξί είναι τα (R1, R2, R4, R5, R7, R8). Το σύνολο δοκιμής αλλοιώνεται μηδενίζοντας εναλλάξ όλα τα κανάλια που αντιστοιχούν στο δεξί και στο αριστερό αυτί. Ουσιαστικά, η εν λόγω αλλοίωση αφορά την δεύτερη διάσταση των δεδομένων (τα κανάλια). Στο Σχήμα 6.16 απεικονίζεται η ακρίβεια των προβλέψεων σε κάθε περίπτωση. Φαίνεται πως τα κανάλια που αντιστοιχούν στο δεξί αυτί οδηγούν στη λήψη απόφασης με μεγαλύτερη ακρίβεια.

Στη συνέχεια, λαμβάνει χώρα μια διαφορετική αλλοίωση του συνόλου δοκιμής. Ελέγχεται αν τα κανάλια που τοποθετούνται στην μπροστά (front) ή στην πίσω πλευρά (bottom) του αυτιού οδηγούν το δίκτυο σε προβλέψεις μεγαλύτερης ακριβείας. Τα κανάλια που τοποθετούνται στην μπροστινή πλευρά του αυτιού είναι, όπως φαίνεται και στο Σχήμα 4.2, τα L1, L2, L9, L10, R1, R2, R7, R8, ενώ αυτά που τοποθετούνται στην πίσω είναι τα L4, L5, L6, L7, R4, R5. Το σύνολο δοκιμής αλλοιώνεται μηδενίζοντας εναλλάξ όλα τα κανάλια που τοποθετούνται στην πίσω και στην μπροστινή πλευρά του αυτιού. Στο Σχήμα 6.17 απεικονίζεται η ακρίβεια των προβλέψεων σε κάθε περίπτωση. Φαίνεται πως τα κανάλια που τοποθετούνται στην πίσω πλευρά οδηγούν στη λήψη απόφασης με μεγαλύτερη ακρίβεια.



Σχήμα 6.16: Accuracy Score



Σχήμα 6.17: Accuracy Score

Κεφάλαιο 7

Ανακεφαλαίωση και Μελλοντικές Προεκτάσεις

Στην παρούσα διπλωματική εργασία διερευνήθηκε το πεδίο της βιοϊατρικής τεχνολογίας που αφορά τη χρήση ηλεκτροεγκεφαλογράφηματος από την περιοχή του αυτιού, της ψηφιακής και προηγμένης επεξεργασίας σήματος μέσω της χρήσης της τεχνικής Αποσύνθεσης Σμήνους και της βαθιάς μηχανικής μάθησης, μέσω συνελικτικών νευρωνικών δικτύων.

Όπως έχει, ήδη, αναφερθεί, κατά την υλοποίηση της παρούσας εργασίας, επιδιώχθηκε να γίνει η διάκριση της κινητικής κατάστασης με ταυτόχρονη εκμετάλλευση της παράλληλης αλλαγής της μορφής του καθαρού EEG σήματος και του moving artifact σε κάθε σενάριο κίνησης με δεδομένη ταχύτητα. Η διατήρηση των moving artifacts συνέβαλε στην απόφαση ταξινόμησης περί ακινησίας ή κίνησης. Θεωρείται πως η ύπαρξη των αργών components των moving artifacts (που εμφανίζονται στις χαμηλές συχνότητες [56]) βοήθησε στην απόφαση ταξινόμησης, μιας και αυτή η περιοχή προέκυψε η πιο σημαντική για την απόφαση του δικτύου.

Ιδιαίτερα ενδιαφέρουσα ήταν η πρόκληση χρήσης συνελικτικών νευρωνικών δικτύων για το πρόβλημα ταξινόμησης των δύο κλάσεων (ακινησίας και κίνησης) στα δεδομένα ηλεκτροεγκεφαλογράφηματος από την περιοχή του αυτιού. Η ιδέα πως υπάρχει χρήσιμη πληροφορία στις κυματομορφές των σημάτων ηλεκτροεγκεφαλογράφηματος και ότι με χρήση συνελικτικών δικτύων θα είναι δυνατός ο εντοπισμός προτύπων στις κυματομορφές επιβεβαιώθηκε. Η χρήση Αποσύνθεσης Σμήνους βοήθησε στην δημιουργία απλούστερων συχνοτικά κυματομορφών, στις οποίες η ανίχνευση προτύπων από τα συνελικτικά δίκτυα θεωρείται ευκολότερη. Βέβαια, αξίζει να αναφερθεί πως αυτό δεν δηλώνει ότι θα ήταν αδύνατο να ανιχνευτούν πρότυπα στα αρχικά σήματα (αρχικές κυματομορφές), αλλά θα ήταν αναγκαία η χρήση πολύπλοκων νευρωνικών δικτύων με πολύ περισσότερα επίπεδα (μεγαλύτερο βάθος) και αυτή η ενέργεια θα απαιτούσε σαφώς μεγαλύτερο χρόνο εκπαίδευσης και περισσότερους υπολογιστικούς πόρους.

Περαιτέρω έρευνα είναι απαραίτητο να λάβει χώρα προκειμένου να εξαχθούν σαφή συμπεράσματα για την χρησιμότητα των moving artifacts σε φυσικά περιβάλλοντα και τη δυνατότητα διάκρισης δραστηριοτήτων ατόμων βάσει της μορφής τους. Σαν μελλοντική επέκταση της παρούσας εργασίας θα αποτελούσε η υλοποίηση παρόμοιας μεθοδολογίας για σήματα ear-EEG μεγαλύτερης χρονικής διάρκειας (μεγαλύτερη από 1 sec), ώστε να είναι βέβαιο πως το αργό component των moving artifacts προλαβαίνει να εμφανιστεί ολόκληρο. Ενδεχομένως, θα μπορούσε να ερευνηθεί και η δημιουργία διαφορετικού αριθμού συχνοτικών συνιστωσών (διαφορετικό, δηλαδή, από 4) μετά την εφαρμογή

της αποσύνθεσης σμήνους.

Παράρτημα Α΄

Εργαλεία

Η ανάλυση που πραγματοποιήθηκε στα πλαίσια της παρούσας εργασίας υλοποιήθηκε με τις γλώσσες Matlab R2022b και Python 3.10.9.

Η φόρτωση των δεδομένων ear-EEG και η προεπεξεργασία τους έγινε με τη βοήθεια μια εργαλειοθήκης του Matlab, και συγκεκριμένα με το bbci-toolbox που αποτελεί μια Brain Computer Interface εργαλειοθήκη. Για τον εντοπισμό των προβληματικών καναλιών αξιοποιήθηκε η συνάρτηση *dbscan* (density-based spatial clustering of applications with noise), ενώ για τον υπολογισμό της αποσύνθεσης σμήνους η συνάρτηση *SWD*, η οποία έχει δημιουργηθεί από το Εργαστήριο Επεξεργασίας Σήματος και Βιοϊατρικής Τεχνολογίας του τμήματος.

Οι βιβλιοθήκες της Python που χρησιμοποιήθηκαν για την ανάπτυξη των μοντέλων Μηχανικής Μάθησης, την αξιολόγηση των αποτελεσμάτων και τη δημιουργία διαγραμμάτων, καθώς και για την στατιστική ανάλυση είναι οι εξής:

- pandas 1.5.3
- numpy 1.23.5
- keras 2.12.0
- tensorflow 2.12.0
- scikit-learn 1.2.1
- seaborn 0.12.2
- matplotlib 3.7.0
- scipy 1.10.0

Βιβλιογραφία

- [1] [Online]. Available: <https://pediatric-neurosurgery.com/anatomy>
- [2] [Online]. Available: <https://www.thepartnershipineducation.com/resources/nervous-system>
- [3] G. Sergiadis, “Biomedical technology,” *Thessaloniki: Aristotle University Press*, 1992.
- [4] A. F. Jackson and D. J. Bolger, “The neurophysiological bases of eeg and eeg measurement: A review for the rest of us,” *Psychophysiology*, vol. 51, no. 11, pp. 1061–1071, 2014. [Online]. Available: <https://onlinelibrary.wiley.com/doi/abs/10.1111/psyp.12283>
- [5] [Online]. Available: https://en.wikipedia.org/wiki/Action_potential
- [6] M. Tudor, L. Tudor, and K. I. Tudor, “[hans berger (1873-1941)–the history of electroencephalography],” *Acta medica Croatica : casopis Hrvatske akademije medicinskih znanosti*, vol. 59, no. 4, p. 307—313, 2005.
- [7] [Online]. Available: <https://www.bem.fi/book/13/13.htm>
- [8] [Online]. Available: https://www.researchgate.net/figure/The-measurement-and-display-of-EEG-on-human-brains-with-electrodes-8_fig1_339683168
- [9] D. Looney, P. Kidmose, C. Park, M. Ungstrup, M. L. Rank, K. Rosenkranz, and D. P. Mandic, “The in-the-ear recording concept: User-centered and wearable brain monitoring,” *IEEE Pulse*, vol. 3, no. 6, pp. 32–42, 2012.
- [10] [Online]. Available: <https://www.sciencedirect.com/topics/agricultural-and-biological-sciences/brain-waves>
- [11] J. N. Knight, “Signal fraction analysis and artifact removal in eeg,” Ph.D. dissertation, Colorado State University Fort Collins, CO, USA, 2003.
- [12] D. H. R. Blackwood and W. J. Muir, “Cognitive brain potentials and their application,” *The British Journal of Psychiatry*, vol. 157, no. S9, p. 96–101, 1990.
- [13] M. D. Rugg and M. G. H. Coles, *Electrophysiology of Mind: Event-related Brain Potentials and Cognition*. Oxford University Press, 09 1996. [Online]. Available: <https://doi.org/10.1093/acprof:oso/9780198524168.001.0001>

- [14] A. J. Casson, “Wearable eeg and beyond,” *Biomedical engineering letters*, vol. 9, no. 1, pp. 53–71, 2019.
- [15] M. G. Bleichner and S. Debener, “Concealed, unobtrusive ear-centered eeg acquisition: cee-grids for transparent eeg,” *Frontiers in human neuroscience*, 2017.
- [16] S. Kappel, D. Looney, P. Kidmose, and P. Kidmose, “Physiological artifacts in scalp eeg and ear-eeg,” *BioMedical Engineering OnLine*, vol. 16, 08 2017.
- [17] S. L. Kappel, M. L. Rank, H. O. Toft, M. Andersen, and P. Kidmose, “Dry-contact electrode ear-eeg,” *IEEE Transactions on Biomedical Engineering*, vol. 66, no. 1, pp. 150–158, 2019.
- [18] P. Kidmose, D. Looney, M. Ungstrup, M. L. Rank, and D. P. Mandic, “A study of evoked potentials from ear-eeg,” *IEEE Transactions on Biomedical Engineering*, vol. 60, no. 10, pp. 2824–2830, 2013.
- [19] A. Meiser, F. Tadel, S. Debener, and M. Bleichner, “The sensitivity of ear-eeg: Evaluating the source-sensor relationship using forward modeling,” *Brain Topography*, vol. 33, 11 2020.
- [20] S. Petersen and M. Posner, “The attention system of the human brain: 20 years after,” *Annual review of neuroscience*, vol. 35, pp. 73–89, 04 2012.
- [21] C. Niell and M. Stryker, “Modulation of visual responses by behavioral state in mouse visual cortex,” *Neuron*, vol. 65, pp. 472–9, 02 2010.
- [22] J. E. Kline, H. J. Huang, K. L. Snyder, and D. P. Ferris, “Isolating gait-related movement artifacts in electroencephalography during human walking,” *Journal of Neural Engineering*, vol. 12, no. 4, p. 046022, jun 2015. [Online]. Available: <https://dx.doi.org/10.1088/1741-2560/12/4/046022>
- [23] K. T. Sweeney, S. F. McLoone, and T. E. Ward, “The use of ensemble empirical mode decomposition with canonical correlation analysis as a novel artifact removal technique,” *IEEE Transactions on Biomedical Engineering*, vol. 60, no. 1, pp. 97–105, 2013.
- [24] T.-P. Jung, S. Makeig, M. Westerfield, J. Townsend, E. Courchesne, and T. J. Sejnowski, “Removal of eye activity artifacts from visual event-related potentials in normal and clinical subjects,” *Clinical Neurophysiology*, vol. 111, no. 10, pp. 1745–1758, 2000. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S1388245700003862>
- [25] G. K. Apostolidis and L. J. Hadjileontiadis, “Swarm decomposition: A novel signal analysis using swarm intelligence,” *Signal Processing*, vol. 132, pp. 40–50, 2017. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S0165168416302304>
- [26] E. Alpaydin, *Introduction to Machine Learning*, 2nd ed. The MIT Press, 2010.
- [27] P. Cunningham, M. Cord, and S. J. Delany, *Supervised Learning*. Berlin, Heidelberg: Springer Berlin Heidelberg, 2008, pp. 21–49. [Online]. Available: https://doi.org/10.1007/978-3-540-75171-7_2

- [28] T. Hastie, J. Friedman, and R. Tibshirani, *Unsupervised Learning*. New York, NY: Springer New York, 2001, pp. 437–508. [Online]. Available: https://doi.org/10.1007/978-0-387-21606-5_14
- [29] Z. Ding, Y. Huang, H. Yuan, and H. Dong, *Introduction to Reinforcement Learning*. Singapore: Springer Singapore, 2020, pp. 47–123. [Online]. Available: https://doi.org/10.1007/978-981-15-4095-0_2
- [30] [Online]. Available: <https://www.simplilearn.com/tutorials/machine-learning-tutorial/machine-learning-steps>
- [31] [Online]. Available: <https://galaxyinferno.com/what-is-validation-data-used-for-machine-learning-basics/>
- [32] [Online]. Available: <https://plat.ai/blog/confusion-matrix-in-machine-learning/>
- [33] [Online]. Available: https://en.wikipedia.org/wiki/Receiver_operating_characteristic
- [34] [Online]. Available: https://www.reddit.com/r/learnmachinelearning/comments/qiid2e/kmeans_clustering_algorithm/
- [35] [Online]. Available: <https://medium.com/analytics-vidhya/cluster-analysis-with-dbscan-density-based-spatial-clustering-of-applications-with-noise-6ade1ec23555>
- [36] [Online]. Available: <https://www.geeksforgeeks.org/dbscan-clustering-in-ml-density-based-clustering/>
- [37] [Online]. Available: <https://www.superannotate.com/blog/activation-functions-in-neural-networks>
- [38] [Online]. Available: <https://www.turing.com/kb/how-to-choose-an-activation-function-for-deep-learning>
- [39] S. Albawi, T. A. Mohammed, and S. Al-Zawi, “Understanding of a convolutional neural network,” in *2017 international conference on engineering and technology (ICET)*. Ieee, 2017, pp. 1–6.
- [40] I. Tabian, H. Fu, and Z. S. Khodaei, “A Convolutional Neural Network for Impact Detection and Characterization of Complex Composite Structures,” *Sensors*, vol. 19, no. 22, p. 4933, Nov. 2019.
- [41] R. Jin and Q. Niu, “Automatic fabric defect detection based on an improved yolov5,” *Mathematical Problems in Engineering*, vol. 2021, pp. 1–13, 09 2021.
- [42] S. Wang, C. Tang, J. Sun, J. Yang, C. Huang, P. Phillips, and Y. Zhang, “Multiple sclerosis identification by 14-layer convolutional neural network with batch normalization, dropout, and stochastic pooling,” *Frontiers in Neuroscience*, vol. 12, p. 818, 11 2018.
- [43] [Online]. Available: <https://www.baeldung.com/cs/neural-networks-conv-fc-layers>

- [44] [Online]. Available: <https://aiaspirant.com/dropout-for-regularization/>
- [45] S. D. C. Team, “Metadata record for: Mobile BCI dataset of scalp- and ear-EEGs with ERP and SSVEP paradigms while standing, walking, and running,” 12 2021. [Online]. Available: https://springernature.figshare.com/articles/dataset/Metadata_record_for_Mobile_BCI_dataset_of_scalp_and_ear-EEGs_with_ERP_and_SSVEP_paradigms_while_standing_walking_and_running/16669072
- [46] E. Donchin, “Surprise!... surprise?” *Psychophysiology*, vol. 18, no. 5, pp. 493–513, 1981. [Online]. Available: <https://onlinelibrary.wiley.com/doi/abs/10.1111/j.1469-8986.1981.tb01815.x>
- [47] C. C. Duncan-Johnson and E. Donchin, “The p300 component of the event-related brain potential as an index of information processing,” *Biological Psychology*, vol. 14, no. 1, pp. 1–52, 1982. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/0301051182900163>
- [48] K. R. Malihe Sabeti, Reza Boostani, “How mental fatigue affects the neural sources of p300 component,” *JIN*, vol. 17, no. 1, pp. 72–81, 2018.
- [49] J. M. FORD, “Schizophrenia: The broken p300 and beyond,” *Psychophysiology*, vol. 36, no. 6, p. 667–682, 1999.
- [50] C. F. Blanco-Díaz, C. D. Guerrero-Méndez, T. Bastos-Filho, S. Jaramillo-Isaza, and A. F. Ruiz-Olaya, “Effects of the concentration level, eye fatigue and coffee consumption on the performance of a bci system based on visual erp-p300,” *Journal of Neuroscience Methods*, vol. 382, p. 109722, 2022. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S0165027022002485>
- [51] R. Zink, B. Hunyadi, S. Huffel, and M. de Vos, “Mobile eeg on the bike: Disentangling attentional and physical contributions to auditory attention tasks,” *Journal of neural engineering*, vol. 13, p. 046017, 06 2016.
- [52] [Online]. Available: https://en.wikipedia.org/wiki/Spectral_density
- [53] [Online]. Available: <https://sebastianraschka.com/blog/2022/confidence-intervals-for-ml.html>
- [54] [Online]. Available: https://sphweb.bumc.bu.edu/otlt/mph-modules/bs/bs704_confidence_intervals/bs704_confidence_intervals_print.html
- [55] B. Efron and R. J. Tibshirani, *An introduction to the bootstrap*. CRC press, 1994.
- [56] K. Sweeney, “Motion artifact processing techniques for physiological signals,” Ph.D. dissertation, 04 2013.